



UNIVERSIDAD DE BUENOS AIRES
FACULTAD DE CIENCIAS EXACTAS Y NATURALES

Cuantización Conjunta de Medidas para Aprendizaje Automático

Tesis de Licenciatura en Ciencias de Datos

Noelia Falczuk

Director: Pablo Groisman

Codirectora: Mariela Sued

Buenos Aires, 2025

CUANTIZACIÓN CONJUNTA DE MEDIDAS PARA APRENDIZAJE AUTOMÁTICO

El Aprendizaje Automático (*Machine Learning*) requiere el manejo eficiente de grandes volúmenes de datos, lo que impone desafíos en términos de procesamiento. Una técnica clave para abordarlos es la cuantización de medidas, que busca reemplazar una medida de probabilidad μ con una versión discreta, con un soporte finito y más pequeño, que la aproxime de manera óptima.

Esta tesis profundiza en el marco teórico y las aplicaciones de la cuantización, partiendo de los fundamentos teóricos como la Distancia de Wasserstein [1, 2, 3] y el concepto de Baricentro de Wasserstein [4, 5]. Se exploran los principios de la cuantización de una única medida [6, 7], incluyendo su conexión con el algoritmo de k -means y cuantización de medidas [8].

Además, en este trabajo exploramos una nueva idea: la Cuantización Conjunta de Medidas, la cual extiende el principio de aproximación óptima a un conjunto de medidas $(\mu_1, \dots, \mu_N)$. Su objetivo es encontrar un único cuantizador que minimice simultáneamente la pérdida de información para todas las medidas.

Finalmente, los resultados obtenidos demuestran que la cuantización, formulada bajo este enfoque, no solo logra una aproximación eficiente de las medidas individuales, sino que también establece un método efectivo para aproximar el Baricentro de Wasserstein de un conjunto de medidas. Esta aproximación cuantizada del Baricentro simplifica significativamente su cálculo, ofreciendo una herramienta computacionalmente más viable para tareas centrales en el *Machine Learning* que dependen de la agregación óptima de distribuciones de probabilidad [9, 10, 11, 12, 13].

AGRADECIMIENTOS

Mamá, papá, Dani, abuelos, familia, amigos... muchas gracias por haberme acompañado durante todo este camino. Aunque esta tesis muestra algo de cuánto aprendí y crecí durante estos años, no lo es todo. Una parte muy importante de este recorrido se construyó fuera de Exactas. Los cimientos que me hicieron ser quien soy y que me permitieron lograr lo que hoy nos reúne, los construyeron, y los siguen construyendo, ustedes, todos los días. Nada de esto hubiese sido posible sin su compañía

Nos reímos, lloramos, nos divertimos y nos escuchamos. Escuchamos música, jugamos juegos de mesa y al backgammon, jugamos al tenis, cocinamos, compramos ropa juntas, nos arreglamos, salimos a bailar, a merendar y a cenar, nos fuimos a la playa, hicimos asados, festejamos cumpleaños, compartimos recreos en la facultad y en el colegio. Con todo eso, y mucho más, me acompañaron cada día. Este es un logro que construimos entre todos y por eso quiero agradecerles.

Mamá y papá, gracias por cuidarme y apoyarme siempre, por quererme tal como soy sin pedirme nada a cambio, por impulsarme a estudiar y permitirme elegir. Gracias, mamá, por enseñarme a esforzarme, a estudiar y a buscar dar siempre lo mejor; por esperarme tantas veces con el almuerzo o la cena, por aconsejarme y abrazarme incondicionalmente. Gracias, papá, por tus chistes que lograban quitarle peso a la importancia de una simple nota, y por iniciarme en el deporte y jugar al tenis conmigo. Dani, como vos, hermana no hay. Gracias por ser mi compinche.

A mi Familia, los Falczuk, abu de capi y los Garcia. Las risas y la comida nunca faltaron. Abuelo Tito y Abu de Tigre, a ustedes una medición especial. Gracias por amarme, por enseñarme qué es la calma, cuidarme desde chiquitita y quererme mucho. Me enseñaron a ver la vida de otra manera.

Demi, gracias por ser el mejor compañero que alguien pudiera imaginar. Gracias por sacarme una sonrisa todos los días, por ser quien me da paz, por distraerme de las responsabilidades sin intentarlo, por todos esos paseos y planes del año que me hicieron y hacen muy feliz. Gracias por apoyarme y amarme siempre.

Por supuesto, gracias “Juntadas (...)”, amigos del colegio y para siempre. Gracias, Joaco, por traer siempre un juego nuevo a la mesa; Lolo, por escuchar siempre; Juani, mi mamá dentro del grupo; Larry y todos tus chistes; Pikki, por ser mi cómplice; Reni, por tu sonrisa constante y tu risa contagiosa; Pablito y Ema, por su

tranquilidad; y Luven, por nuestras cenas de largas charlas. Las palabras no alcanzan para agradecerles todo.

Gracias “Geogebra”. Ustedes, hicieron que la experiencia facultativa valiera la pena: juntadas, risas y mates entre y durante las clases. Gracias a ustedes, disfrutaba despertarme tan temprano para cursar todo el día y volver agotada a casa. Tomi, Tade, Marian, a ustedes especialmente les digo: todavía nos quedan muchas cenas.

Pablo y Mariela, mis directores, un agradecimiento especial para ustedes, que sin conocerme confiaron en mí, me ayudaron, me incluyeron y me apoyaron enormemente.

Gracias a Pablo Negri, por haber confiado en mí e incluirme en tus proyectos.

Finalmente, muchas gracias a aquellos que quizás no me conocen y que tal vez nunca conoceré, pero que hacen que la universidad funcione todos los días. Gracias a los profesores y profesoras que cada día se paran frente a un pizarrón para dar una clase invaluable y con pasión, porque si no fuese por ellos, si no fuese por su vocación, hoy ninguno de nosotros estaría donde está. Estoy eternamente agradecida y orgullosa de la universidad y de sus docentes.

Sin más, acompáñenme a contarles lo que estuve estudiando. Y perdón... porque hoy tampoco va a ser la excepción: mamá, papá, amigos... gracias por seguir asintiendo con la cabeza y preguntando como siempre, aun cuando no entiendan del todo... o nada.

Índice general

1..	Introducción	1
2..	Preliminares	5
2.1.	Distancia de Wasserstein	5
2.2.	Baricentro de Wasserstein	9
3..	Cuantización de medidas	17
3.1.	Definiciones y nociones básicas	17
3.1.1.	Función cuantizadora y k -means	17
3.1.2.	Cuantizando medidas	19
3.2.	El cuantizador como medida imagen μf^{-1}	20
3.3.	Convergencia de cuantizadores óptimos	21
4..	Cuantización conjunta de medidas	24
4.1.	Cuantización conjunta de medidas	24
5..	Aplicaciones	32
5.1.	Conditional flow matching for generative modeling	32
5.1.1.	Flow matching	32
5.1.2.	Construcción de p_t, u_t a partir de trayectorias de probabilidad condicionales y campos vectoriales	34
5.1.3.	Conditional flow matching	35
5.1.4.	Implementación	35
5.1.5.	Consideraciones	38
5.2.	Aprendizaje federado	43
5.2.1.	Introducción	43
6..	Conclusión	50
7..	Apéndice	52

1. INTRODUCCIÓN

El aprendizaje automático y la estadística computacional se han convertido en herramientas esenciales para analizar y modelar datos provenientes de diversos fenómenos. En muchos de estos problemas, la información disponible no puede representarse mediante un conjunto pequeño de puntos o parámetros, sino mediante distribuciones de probabilidad que describen la incertidumbre o variabilidad del sistema. En otros casos, la cantidad de datos disponibles es enorme e incluso continúa creciendo, especialmente en esta era de digitalización y producción masiva de información.

Sin embargo, trabajar directamente con distribuciones continuas o con conjuntos de datos de gran tamaño suele ser costoso o incluso inabordable desde el punto de vista computacional. Esto motiva la necesidad de desarrollar métodos que permitan aproximar o representar una medida de probabilidad mediante una versión discreta, preservando las características más importantes.

Aquí surge la **cuantización de medidas**, que busca reemplazar una distribución compleja por una combinación convexa de pocos puntos —llamados *cuantizadores*— minimizando la pérdida de información medida en una métrica adecuada, como la distancia de Wasserstein. Este enfoque conecta naturalmente con algoritmos ampliamente utilizados en aprendizaje automático, como *k-means*, y con modelos más recientes basados en transporte óptimo y baricentros de Wasserstein.

Para ilustrar la idea, consideremos una variable aleatoria $X \sim \mathcal{N}(0, 1)$ con distribución normal estándar. Su densidad es continua y toma infinitos valores posibles, pero puede aproximarse mediante una medida discreta formada por tres masas de probabilidad ubicadas, en este caso, en el cero y en dos puntos simétricos alrededor del eje $x = 0$. Esta aproximación minimiza el error medido en la distancia de Wasserstein W_2 , y puede verse como una *forma óptima de resumir la información* contenida en la distribución original (Ver la Figura 1.1).

Geométricamente, esto equivale a reemplazar la campana continua por tres “masas de probabilidad” ubicadas en los puntos que mejor resumen la forma de la normal. Desde un punto de vista práctico, equivale a representar un conjunto de datos gaussianos con tres *centroides*, de manera similar al resultado de un algoritmo de *clustering*. De esta forma, la cuantización puede interpretarse como una *versión teóricamente óptima del agrupamiento de los datos* que busca preservar las estruc-




Fig. 1.1: Distribución normal $\mathcal{N}(0, 1)$. Las líneas punteadas en $x = -\sqrt{\frac{2}{\pi}}$, 0 y $\sqrt{\frac{2}{\pi}}$ indican las posiciones de los k -cuantizadores o centros.

tura de la distribución.

Veamos otro ejemplo: consideremos dos variables aleatorias normales univariadas, una $X_1 \sim \mathcal{N}(-1, 1)$ y otra $X_2 \sim \mathcal{N}(1, 1)$. Ambas distribuciones pueden aproximarse simultáneamente mediante una medida discreta compuesta por tres masas de probabilidad ubicadas en el origen y en dos puntos simétricos respecto del eje $x = 0$ (véase la Figura 1.2). Esta medida —indicada en la figura mediante líneas punteadas— es la que proporciona la mejor aproximación simultánea a ambas normales.

Por otro lado, podemos buscar el **baricentro de Wasserstein teórico** de estas dos distribuciones, que sería como buscar la cuantización pero continua. En este caso, se obtiene nuevamente una distribución normal con varianza 1 y media igual al promedio de las medias originales. En este caso, el baricentro es: $\mathcal{N}(0, 1)$, lo que refleja el equilibrio entre las dos distribuciones iniciales (Ver la Figura 1.2).

Este ejemplo muestra cómo el concepto de baricentro de Wasserstein permite “promediar” de manera óptima distribuciones distintas. En particular, ilustra la motivación del estudio de cuantización conjunta de medidas pues la cuantización es un método de discretizar el problema que aborda la búsqueda del baricentro.

El objetivo principal de esta tesis es desarrollar un **marco teórico general para la cuantización de medidas en espacios de Wasserstein**, estableciendo resultados de existencia, unicidad y convergencia de cuantizadores óptimos, así como tasas de convergencia en el caso empírico. También se analizan extensiones al caso conjunto de varias medidas, lo que permite conectar la cuantización con el concepto de baricentro de Wasserstein, ampliamente utilizado en problemas de agregación y




Fig. 1.2: Distribuciones normales $\mathcal{N}(-1, 1)$, $\mathcal{N}(1, 1)$ y el baricentro teórico $\mathcal{N}(0, 1)$. Las líneas punteadas en $x = -1,1666$, 0 y $1,1666$ indican las posiciones de los cuantizadores o centros.

aprendizaje federado.

Además de su interés teórico, los resultados obtenidos poseen aplicaciones directas en tareas de aprendizaje automático, como la compresión y representación de datos, la agregación de modelos y el desarrollo de modelos generativos basados en transporte óptimo.

Un ejemplo de problema práctico que motiva este trabajo es el siguiente: supongamos que se dispone de datos de individuos provenientes de distintos países, con condiciones económicas y políticas diversas. En este caso, es esperable que los datos no sigan la misma distribución. Si se trata, por ejemplo, de resultados médicos de pacientes, puede ser deseable entrenar un modelo que sea independiente del país de origen y que clasifique únicamente en función de la condición médica o de variables relevantes. Para lograrlo, sería necesario identificar sobre qué datos entrenar el modelo de modo que represente el espacio de información esencial, sin verse afectado por las diferencias regionales. Aquí, la cuantización sobre los datos originales permite determinar qué puntos representan simultáneamente a ambas distribuciones, proporcionando una representación robusta y equitativa de la información.

La tesis se organiza del siguiente modo:

- En el **Capítulo 2** se presentan los preliminares teóricos: la distancia y el espacio de Wasserstein, y el concepto de baricentro.
- En el **Capítulo 3** se desarrolla la teoría de cuantización de medidas, su relación con el problema de transporte y los resultados de existencia y convergencia de cuantizadores.

-
- En el **Capítulo 4** se presenta por primera vez el problema de cuantización conjunta de medidas y resultados teóricos de convergencia.
 - Finalmente, en el **Capítulo 5** se discuten aplicaciones de la teoría al aprendizaje automático a la ciencia de datos.

A lo largo de la tesis asumimos que los espacios considerados son completos, separables y Heine-Borel. Es decir, los conjuntos cerrados y acotados son compactos.

2. PRELIMINARES

En esta sección introducimos las nociones básicas necesarias para el desarrollo de los resultados de cuantización. Comenzamos recordando la definición de la distancia de Wasserstein, que permite cuantificar la diferencia entre medidas de probabilidad y constituye la base de muchos problemas de optimización en espacios de medidas. Luego, presentamos la noción de baricentro de Wasserstein, que podría entenderse como un promedio en contextos donde los elementos son medidas en lugar de puntos en un espacio. Ambas nociones serán fundamentales para definir y analizar los cuantizadores óptimos de medidas en las secciones siguientes.

Para profundizar más en los temas que se presentan a continuación se recomienda mirar el libro “An Invitation to Statistics in Wasserstein Space” [2].

2.1. Distancia de Wasserstein

Como se mencionó anteriormente, el problema de cuantización consiste en encontrar una distribución discreta que aproxime de la mejor manera posible a una distribución, ya sea continua o discreta (en el caso discreto, una con un número menor de puntos en el soporte). Para ello, necesitamos una medida que permita cuantificar el costo o error asociado a dicha aproximación.

A partir de una función de costo que indique cuánto “cuesta” aproximar un punto de la distribución continua por otro de la discreta, es posible definir un costo total de aproximación. Contar con una función de este tipo permite evaluar cuánta información se pierde al reemplazar una distribución por otra y determinar qué conjunto discreto de puntos representa mejor a la distribución original según el problema en estudio.

En particular, veremos que existe una función, una verdadera distancia entre distribuciones y será la que utilizaremos para comparar distribuciones. Este tipo de distancia, cuando se define a partir del costo euclidiano, tiene numerosas aplicaciones en procesamiento de imágenes, donde se utiliza para comparar distribuciones de colores (ya sea en espacio RGB o en escala de grises). También se ha aplicado en el entrenamiento de redes generativas (GANs), para comparar distribuciones de datos sintéticos con reales.

A fin de formalizar la noción de “costo” al aproximar distribuciones de probabi-

lidad, primero debemos especificar el conjunto de medidas con el que trabajaremos. Este conjunto es el *espacio de Wasserstein*, formado por todas aquellas medidas de probabilidad que poseen un momento p -ésimo finito. Esta condición garantiza que el costo de transporte esté bien definido y sea finito. A continuación definimos este espacio de medidas.

Definición 1 (Espacio de Wasserstein). Sea (E, d) un espacio métrico polaco. Para $p \geq 1$, el p -espacio de Wasserstein sobre E se define como

$$\mathcal{W}_p(E) := \left\{ \mu \in \mathcal{P}(E) : \int_E d(x_0, x)^p \mu(dx) < +\infty \right\}, \quad (2.1)$$

donde $x_0 \in E$ es arbitrario. Es el conjunto de todas las medidas de probabilidad sobre E con *momento p -ésimo finito*. No depende de la elección del punto x_0 .

Para cuantificar la diferencia entre dos medidas $\mu, \nu \in \mathcal{W}_p(E)$ o el “costo” de aproximar una distribución por otra, necesitamos una herramienta que las relacione. Esta herramienta será la Distancia de Wasserstein y se define a partir del concepto de acoplamiento de medidas.

Un acoplamiento es una medida conjunta que establece una correlación entre los puntos de las dos distribuciones dadas. Veamos la definición:

Definición 2 (Acoplamiento). Sean $\mu, \nu \in \mathcal{W}_p(E)$, una medida $\pi \in \mathcal{P}(E \times E)$ se llama *acoplamiento* de μ y ν si sus marginales son exactamente μ y ν , es decir, si para todo conjunto medible $A \subseteq E$ se cumple

$$\pi(A \times E) = \mu(A) \quad \text{y} \quad \pi(E \times A) = \nu(A).$$

El conjunto de todos los acoplamientos entre μ y ν se denota por

$$\Pi(\mu, \nu) = \{ \pi \in \mathcal{P}(E \times E) \mid \pi(A \times E) = \mu(A), \pi(E \times A) = \nu(A) \quad \forall A \subseteq E \text{ medible} \}.$$

El conjunto $\Pi(\mu, \nu)$ contiene todos los posibles acoplamientos entre las medidas μ y ν . Sin embargo, para cuantificar la diferencia entre ellas, necesitamos identificar el acoplamiento que produce el mínimo costo al aproximar μ por ν . Este acoplamiento define la distancia de Wasserstein:

Definición 3. Distancia de Wasserstein. Para dos medidas de probabilidad cualesquiera $\mu, \nu \in \mathcal{W}_p(E)$, la distancia de Wasserstein de orden p entre μ y ν se define mediante la fórmula

$$\begin{aligned}
W_p(\mu, \nu) &= \left(\inf_{\pi \in \Pi(\mu, \nu)} \int_{E \times E} d(x, y)^p d\pi(x, y) \right)^{1/p} \\
&= \inf \left\{ \mathbb{E}[d(X, Y)^p]^{1/p} : X \sim \mu, Y \sim \nu \right\}.
\end{aligned}$$

Prueba de que W_p es finito en $\mathcal{W}_p(E)$.

Demostración. Sea π un acoplamiento entre dos medidas μ y ν en $\mathcal{W}_p(E)$. Entonces la desigualdad

$$d(x, y)^p \leq 2^{p-1} (d(x, x_0)^p + d(x_0, y)^p)$$

muestra que $d(x, y)^p$ es integrable siempre que $d(\cdot, x_0)^p$ sea μ -integrable y $d(x_0, \cdot)^p$ sea ν -integrable. $\square$

Se puede demostrar que existe un acoplamiento que realiza el infimo y que, efectivamente, W_p resulta una distancia.

Al dotar al conjunto $\mathcal{W}_p(E)$ con la distancia de Wasserstein W_p , obtenemos el **espacio métrico** $(\mathcal{W}_p(E), W_p)$. Es decir, la distancia W_p define efectivamente una métrica (finita) sobre $\mathcal{W}_p(E)$.

Una de las propiedades más relevantes de la distancia de Wasserstein es que permite describir la convergencia de medidas de probabilidad. En particular, a diferencia de la convergencia débil, la métrica de Wasserstein incorpora información adicional sobre los momentos de las distribuciones. El siguiente resultado establece la caracterización de la convergencia en el espacio de Wasserstein:

Teorema 1. *Sea (E, d) un espacio métrico polaco. Entonces*

$$W_p(\mu_n, \mu) \rightarrow 0 \quad \Leftrightarrow$$

$$\mu_n \rightharpoonup \mu \quad (\text{convergencia débil}) \quad \text{y} \quad \int d(x, x_0)^p d\mu_n(x) \rightarrow \int d(x, x_0)^p d\mu(x).$$

Demostración. Esta demostración fue inspirada en las demostraciones presentadas en [1], Capítulo 6, Teorema 6.9

($\Rightarrow$) Supongamos $W_p(\mu_n, \mu) \rightarrow 0$. Existen variables aleatorias $X_n \sim \mu_n$ y $X \sim \mu$ tales que

$$W_p(\mu_n, \mu) = (\mathbb{E}[d(X_n, X)^p])^{\frac{1}{p}}.$$

Luego

$$\mathbb{E}[d(X_n, X)^p] \rightarrow 0.$$

Por Chebyshev,

$$\mathbb{P}(d(X_n, X) > \varepsilon) \leq \frac{\mathbb{E}[d(X_n, X)^p]}{\varepsilon^p} \rightarrow 0.$$

Es decir, $d(X_n, X) \rightarrow 0$ en probabilidad, de donde $X_n \xrightarrow{d} X$ y por lo tanto $\mu_n \rightarrow \mu$.

($\Leftarrow$) Por el teorema de Skorohod, existen $X_n \sim \mu_n$ y $X \sim \mu$ tales que

$$X_n \rightarrow X \quad \text{c.s.}$$

Veamos que $W_p(\mu_n, \mu)^p \leq \mathbb{E}[d(X_n, X)^p] \rightarrow 0$.

Usando la desigualdad triangular:

$$d(X_n, X) \leq d(X_n, x_0) + d(x_0, X),$$

$$d(X_n, X)^p \leq (d(X_n, x_0) + d(x_0, X))^p \leq 2^{p-1} (d(X_n, x_0)^p + d(x_0, X)^p).$$

Usando Fatou:

$$\mathbb{E}[\liminf d(X_n, X)^p] \leq \liminf \mathbb{E}[d(X_n, X)^p].$$

Como $\liminf d(X_n, X)^p = 0$, obtenemos

$$0 \leq \liminf \mathbb{E}[d(X_n, X)^p].$$

Si definimos

$$Y_n = d(X_n, X)^p$$

vemos que $Y_n \rightarrow 0$ c.s. Fijemos $R > 0$ y la $\psi_R(t) = \min\{t, R\}$. Entonces

$$E[Y_n] = E[\psi_R(Y_n)] + E[(Y_n - R) 1_{\{Y_n > R\}}].$$

Como $\psi_R(Y_n) \rightarrow 0$ c.s. y $0 \leq \psi_R(Y_n) \leq R$, por el teorema de convergencia dominada

$$E[\psi_R(Y_n)] \rightarrow 0.$$

Ahora acotemos $E[(Y_n - R) 1_{\{Y_n > R\}}]$. Si $Y_n > R$ entonces

$$d(X_n, x_0)^p > R/2 \quad \text{o} \quad d(X, x_0)^p > R/2,$$

y por tanto

$$(Y_n - R) 1_{\{Y_n > R\}} \leq 2^{p-1} \left(d(X_n, x_0)^p 1_{\{d(X_n, x_0)^p > R/2\}} + d(X, x_0)^p 1_{\{d(X, x_0)^p > R/2\}} \right).$$

Tomando esperanza,

$$E[(Y_n - R) 1_{\{Y_n > R\}}] \leq 2^{p-1} \left(E[d(X_n, x_0)^p 1_{\{d(X_n, x_0)^p > R/2\}}] + E[d(X, x_0)^p 1_{\{d(X, x_0)^p > R/2\}}] \right).$$

Por convergencia del p -ésimo momento, existe R tal que

$$\sup_n E[d(X_n, x_0)^p 1_{\{d(X_n, x_0)^p > R/2\}}] < \frac{\varepsilon}{2}, \quad E[d(X, x_0)^p 1_{\{d(X, x_0)^p > R/2\}}] < \frac{\varepsilon}{2}.$$

Por tanto, para ese R y para n arbitrario,

$$E[Y_n 1_{\{Y_n > R\}}] \leq 2^{p-1} \varepsilon.$$

Luego,

$$\limsup_{n \rightarrow \infty} E[Y_n] \leq \limsup_{n \rightarrow \infty} E[\psi_R(Y_n)] + 2^{p-1} \varepsilon = 2^{p-1} \varepsilon.$$

Como $\varepsilon > 0$ era arbitrario, obtenemos $E[Y_n] \rightarrow 0$.

Finalmente, recordando que $Y_n = d(X_n, X)^p$ y dado que $W_p(\mu_n, \mu)^p \leq \mathbb{E}[d(X_n, X)^p]$, concluimos que $W_p(\mu_n, \mu) \rightarrow 0$ $\square$

2.2. Baricentro de Wasserstein

El concepto de *baricentro de Wasserstein* surge como una generalización del baricentro clásico (o media) de puntos en un espacio euclídeo, extendido al caso en que los objetos de interés no son puntos, sino *medidas de probabilidad*. En este contexto, se busca una medida que actúe como un “promedio” respecto de la *distancia de Wasserstein*.

En un espacio euclídeo, dado un conjunto de puntos $x_1, \dots, x_n \in \mathbb{R}^d$ y pesos $w_1, \dots, w_n$ tales que $w_i \geq 0$ y $\sum_{i=1}^n w_i = 1$, el baricentro se obtiene como la solución

del problema de minimización

$$\min_{x \in \mathbb{R}^d} \sum_{i=1}^n w_i \|x_i - x\|^2,$$

cuyo mínimo se alcanza en el punto

$$\bar{x} = \sum_{i=1}^n w_i x_i,$$

es decir, la media.

La misma idea se puede extender a cualquier espacio donde exista una distancia entre puntos. En esos espacios más generales, el baricentro se define como el punto que minimiza la suma de las distancias cuadradas a los datos, ponderadas por w_i :

$$\min_{x \in E} \sum_{i=1}^n w_i d(x_i, x)^2$$

A ese punto se lo llama *media de Fréchet*. Puede no ser único dependiendo de la geometría del espacio.

De manera intuitiva, si ahora consideramos el espacio métrico $\mathcal{W}_p(E)$ formado por *medidas de probabilidad p -integrables* definidas sobre un mismo espacio E , dotado de la *distancia de Wasserstein* W_p , y si en lugar de tener un conjunto de puntos queremos promediar un conjunto de distribuciones $\mu_1, \dots, \mu_n$, podemos extender la noción de baricentro a este contexto, sustituyendo la norma euclídea por la distancia W_p . En este contexto, el baricentro de Wasserstein es la medida ν que minimiza la suma ponderada de las distancias de Wasserstein a cada una de ellas.

Este concepto resulta fundamental en diversas aplicaciones, tales como:

- **Cuantización y compresión:** encontrar una medida representativa que minimice el error de aproximación.
- **Definir el centro de un grupo de medidas como medida resumen**
- **Aprendizaje:** combinar información proveniente de distintas fuentes probabilísticas.

Veamos formalmente qué es el *baricentro de Wasserstein*:

Definición 4. Sea (E, d) un espacio métrico. Dadas medidas de probabilidad $\mu_1, \dots, \mu_n \in \mathcal{W}_p(E)$ y pesos $\lambda_1, \dots, \lambda_n \geq 0$ con $\sum_{i=1}^n \lambda_i = 1$, se llama *baricentro de Wasserstein*

de orden p a una medida $\nu^* \in \mathcal{W}_p(E)$ tal que

$$\nu^* \in \operatorname{argmin}_{\nu \in \mathcal{W}_p(E)} \ell(\nu; \mu_1 \dots \mu_n) \quad (2.2)$$

donde W_p denota la distancia de Wasserstein de orden p y $\ell(\nu; \mu_1 \dots \mu_n) = \sum_{i=1}^n \lambda_i W_p^p(\nu, \mu_i)$

Ejemplo 1. Si $\mu_1 = \mathcal{N}(m_1, \sigma)$ y $\mu_2 = \mathcal{N}(m_2, \sigma)$ son gaussianas con la misma covarianza, el baricentro de Wasserstein de orden 2 con pesos λ_1, λ_2 es nuevamente gaussiano $\mathcal{N}(\lambda_1 m_1 + \lambda_2 m_2, \sigma)$.




Fig. 2.1: Baricentros de Wasserstein de orden 2 entre dos gaussianas $\mathcal{N}(m_1, \sigma)$ y $\mathcal{N}(m_2, \sigma)$ con diferentes pesos λ_1, λ_2 .

Existencia de baricentro en espacio de Wasserstein

Una vez definida la noción de baricentro de Wasserstein como el punto del espacio métrico que minimiza el costo promedio de aproximar una distribución por otra, resulta natural preguntarse bajo qué condiciones dicho minimizador existe; esta cuestión no es trivial. En lo que sigue presentamos un resultado general que garantiza la existencia de baricentros en el espacio de Wasserstein bajo ciertas hipótesis.

Consideremos una medida de probabilidad aleatoria $\tilde{\mu}$ definida sobre $\mathcal{W}_p(E)$, cuya distribución está dada por $\mathbb{P}$. Esta medida $\mathbb{P}$ pertenece al espacio $\mathcal{W}_p(\mathcal{W}_p(E))$, provisto de la métrica de Wasserstein W_p .

Nótese que utilizamos la misma notación W_p tanto para la distancia en $\mathcal{W}_p(E)$ como para la distancia en $\mathcal{W}_p(\mathcal{W}_p(E))$. De este modo, si $\tilde{\mu} \in \mathcal{W}_p(E)$ es una medida aleatoria con distribución $\mathbb{P}$, entonces, para toda $\nu \in \mathcal{W}_p(E)$, se cumple que

$$W_p^p(\delta_\nu, \mathbb{P}) = \mathbb{E}[W_p^p(\nu, \tilde{\mu})] = \int W_p^p(\nu, \mu) d\mathbb{P}(\mu).$$

Dada una probabilidad $\mathbb{P} \in \mathcal{W}_p(\mathcal{W}_p(E))$, consideremos el problema de minimización sobre $\nu \in \mathcal{W}_p(E)$ definido por

$$\nu \mapsto \mathbb{E}[W_p^p(\nu, \tilde{\mu})] = W_p^p(\delta_\nu, \mathbb{P}),$$

donde $\tilde{\mu}$ es una variable aleatoria en $\mathcal{W}_p(E)$ con distribución $\mathbb{P}$.

Si existe una medida ν^* que minimiza esta expresión, entonces ν^* se denomina *baricentro de $\mathbb{P}$* en el espacio de Wasserstein.

Podemos enunciar ahora el resultado de existencia de dicho baricentro.

Teorema 2 (Existencia del baricentro de Wasserstein). *Sea $p \geq 1$ y sea (E, d) un espacio geodésico separable y localmente compacto. Entonces, para $\mathbb{P} \in \mathcal{W}_p(\mathcal{W}_p(E))$, existe un baricentro $\bar{\mu}_{\mathbb{P}}$ definido como*

$$\bar{\mu}_{\mathbb{P}} \in \arg \min_{\nu \in \mathcal{W}_p(E)} \mathbb{E}[W_p^p(\nu, \tilde{\mu})],$$

donde $\tilde{\mu}$ es una medida aleatoria con distribución $\mathbb{P}$.

La demostración de este teorema se encuentra en el artículo de Le Gouic y Loubes [5].

Otro resultado interesante

El siguiente resultado extraído de [5], establece la continuidad del baricentro de Wasserstein respecto de la convergencia de medidas en $\mathcal{W}_p(E)$.

Consideremos una sucesión $(\mathbb{P}_j)_{j \geq 1} \subset \mathcal{W}_p(E)$ que converge a alguna $\mathbb{P} \in \mathcal{W}_p(\mathcal{W}_p(E))$. si todas estas medidas $(\mathbb{P}_j)_{j \geq 1}$ admiten un baricentro (o media de Wasserstein), ¿converge la sucesión de dichos baricentros al baricentro de la medida límite $\mathbb{P}$?

El siguiente teorema proporciona una respuesta garantizando la **continuidad** del baricentro: la secuencia de baricentros converge al baricentro de la medida límite $\mathbb{P}$.

Teorema 3. *Sea $p \geq 1$ y sea (E, d) un espacio geodésico (Ver def. 10) separable y localmente compacto. Sea $(\mathbb{P}_j)_{j \geq 1} \subset \mathcal{W}_p(\mathcal{W}_p(E))$ una sucesión de medidas de probabilidad sobre $\mathcal{W}_p(E)$ y sea μ_j un baricentro de $\mathbb{P}_j$, para todo $j \in \mathbb{N}$. Supongamos que*

para alguna $\mathbb{P} \in \mathcal{W}_p(\mathcal{W}_p(E))$ se cumple que

$$W_p(\mathbb{P}, \mathbb{P}_j) \xrightarrow{j \rightarrow +\infty} 0.$$

Entonces, la sucesión $(\mu_j)_{j \geq 1}$ de baricentros es pre-compacta en $\mathcal{W}_p(E)$ - toda subsucesión de (μ_j) tiene una subsucesión convergente en $\mathcal{W}_p(E)$ - y todo límite es un baricentro de $\mathbb{P}$.

Demostración. 1) Probar que los momentos de orden p de μ_j están acotados.

Sea $\tilde{\mu}_j \sim \mathbb{P}_j$. Luego $\forall x \in E$ se tiene $\delta_x \in \mathcal{W}_p(E)$ y $\delta_{\tilde{\mu}_j}, \delta_{\delta_x} \in \mathcal{W}_p(\mathcal{W}_p(E))$.

Entonces

$$W_p(\mu_j, \delta_x) = W_p(\delta_{\mu_j}, \delta_{\delta_x}).$$

Por desigualdad triangular,

$$\begin{aligned} W_p(\delta_{\mu_j}, \delta_{\delta_x}) &\leq W_p(\delta_{\mu_j}, \mathbb{P}_j) + W_p(\mathbb{P}_j, \delta_{\delta_x}), \\ &= (\mathbb{E}[W_p^p(\mu_j, \tilde{\mu}_j)])^{1/p} + (\mathbb{E}[W_p^p(\tilde{\mu}_j, \delta_x)])^{1/p}. \\ &\leq 2 (\mathbb{E}[W_p^p(\tilde{\mu}_j, \delta_x)])^{1/p} = 2 W_p(\mathbb{P}_j, \delta_{\delta_x}). \end{aligned}$$

Puesto que $\mu_j \sim \mathbb{P}_j$ minimiza,

$$\nu \mapsto \mathbb{E}[W_p^p(\nu, \tilde{\mu}_j)].$$

Además,

$$W_p(\mathbb{P}_j, \delta_{\delta_x}) \leq 2 \left(W_p(\mathbb{P}_j, \mathbb{P}) + W_p(\mathbb{P}, \delta_{\delta_x}) \right) \leq M < \infty.$$

pues $W_p(\mathbb{P}, \mathbb{P}_j) \rightarrow 0$.

Ahora notemos que, usando Markov,

$$\begin{aligned} \mu_j(B(x_0, r)^c) &= \mu_j(x \in E \mid d(x, x_0) \geq r) = \mu_j(d(x, x_0)^p \geq r^p) \\ &\leq \frac{\mathbb{E}_{\mu_j}[d^p(X, x_0)]}{r^p} = \frac{W_p^p(\mu_j, \delta_{x_0})}{r^p} \leq \frac{M^p}{r^p}. \end{aligned}$$

Como la cota es uniforme para todos los j y tomando r es grande, se puede afirmar que $(\mu_j)_j$ es tight. Luego, se puede extraer una subsucesión que converge a una medida μ .

2) μ es baricentro para $\mathbb{P}$ si μ minimiza

$$\nu \mapsto \mathbb{E}[W_p^p(\nu, \tilde{\mu})], \quad \tilde{\mu} \sim \mathbb{P}.$$

Tomemos $\nu \in \mathcal{W}_p(E)$ cualquiera. Entonces

$$\mathbb{E}[W_p^p(\nu, \tilde{\mu})] = W_p^p(\delta_\nu, \mathbb{P}) = \lim_{j \rightarrow \infty} W_p^p(\delta_\nu, \mathbb{P}_j) = \lim_{j \rightarrow \infty} \mathbb{E}[W_p^p(\delta_\nu, \tilde{\mu}_j)], \quad \tilde{\mu}_j \sim \mathbb{P}_j \quad \tilde{\mu} \sim \mathbb{P}.$$

pues $W_p(\mathbb{P}_j, \mathbb{P}) \rightarrow 0$. Además, como μ_j es baricentro de $\mathbb{P}_j$, se cumple

$$\lim_{j \rightarrow \infty} W_p^p(\delta_\nu, \mathbb{P}_j) \geq \lim_{j \rightarrow \infty} \mathbb{E}[W_p^p(\mu_j, \tilde{\mu}_j)]$$

Por Fatou,

$$\liminf_{j \rightarrow \infty} \mathbb{E}[W_p^p(\mu_j, \tilde{\mu}_j)] \geq \mathbb{E}[\liminf_{j \rightarrow \infty} W_p^p(\mu_j, \tilde{\mu}_j)].$$

Por continuidad de W_p como función de dos coordenadas,

$$\mathbb{E}[\liminf_{j \rightarrow \infty} W_p^p(\mu_j, \tilde{\mu}_j)] \geq \mathbb{E}[W_p^p(\mu, \tilde{\mu})]$$

Es decir, sea $\nu \in \mathcal{W}_p(E)$ cualquiera luego

$$\mathbb{E}[W_p^p(\nu, \tilde{\mu})] \geq \mathbb{E}[W_p^p(\mu, \tilde{\mu})]$$

y así μ es baricentro de $\mathbb{P}$.

3) Finalmente, probar que $\mu_j \rightarrow \mu$ en W_p .

Sea $\nu = \mu$, entonces

$$W_p(\delta_\mu, \mathbb{P}_j) \rightarrow W_p(\delta_\mu, \mathbb{P}) = \mathbb{E}[W_p^p(\mu, \tilde{\mu})].$$

$$W_p(\delta_{\mu_j}, \mathbb{P}_j) \rightarrow W_p(\delta_\mu, \mathbb{P}) = \mathbb{E}[W_p^p(\mu, \tilde{\mu})].$$

Pero también

$$W_p^p(\delta_{\mu_j}, \mathbb{P}) - W_p^p(\delta_\mu, \mathbb{P}) \leq W_p^p(\delta_{\mu_j}, \mathbb{P}_j) + W_p^p(\mathbb{P}_j, \mathbb{P}) - W_p^p(\delta_\mu, \mathbb{P}) \rightarrow 0.$$

Esto implica que

$$\mathbb{E}[W_p^p(\mu, \tilde{\mu})] = W_p^p(\delta_\mu, \mathbb{P}) = \lim_{j \rightarrow \infty} W_p^p(\delta_{\mu_j}, \mathbb{P})$$

$$= \lim_{j \rightarrow \infty} \mathbb{E}(W_p^p(\delta_{\mu_j}, \tilde{\mu})) \geq \mathbb{E}(\liminf_{j \rightarrow \infty} W_p^p(\delta_{\mu_j}, \tilde{\mu}))$$

Entonces,

$$\mathbb{E}[W_p^p(\mu, \tilde{\mu})] \leq \mathbb{E}(\liminf_{j \rightarrow \infty} W_p^p(\delta_{\mu_j}, \tilde{\mu})) \leq \mathbb{E}[W_p^p(\mu, \tilde{\mu})]$$

De aquí, usando el lema 3 se concluye que

$$W_p(\mu_j, \mu) \rightarrow 0.$$

□

Veamos un ejemplo, pero antes el siguiente resultado que nos ayudará a construir el ejemplo:

Proposición 1. *Si en el problema del baricentro de Wasserstein $\mu_i = \mathcal{N}(m_i, \Sigma_i)$, entonces el baricentro es una normal cuya media m es el promedio de las medias ($m = \sum w_i m_i$) y su varianza es la única matriz Σ simétrica definida positiva que cumple:*

$$\sum w_i (\Sigma^{1/2} \Sigma_i \Sigma^{1/2})^{1/2} = \Sigma. \quad (2.3)$$

Así, el baricentro es $\bar{\mu} = \mathcal{N}(m, \Sigma)$.

La demostración se puede encontrar completa en [4] o en [3].

Ejemplo 2. *Consideremos el espacio $E = \mathbb{R}$ y tomemos una sucesión de medidas*

$$\mathbb{P}_j = \frac{1}{2} \delta_{\mathcal{N}(-a_j, 1)} + \frac{1}{2} \delta_{\mathcal{N}(a_j, 1)}, \quad a_j \rightarrow 0.$$

Cada $\mathbb{P}_j$ asigna masa igual a dos distribuciones gaussianas centradas en $-a_j$ y a_j , con la misma varianza. A medida que j crece, las dos componentes se acercan entre sí, y la medida $\mathbb{P}_j$ converge en el espacio de Wasserstein hacia

$$\mathbb{P} = \delta_{\mathcal{N}(0, 1)}.$$

El baricentro μ_j de cada $\mathbb{P}_j$ se define como

$$\mu_j = \arg \min_{\mu \in \mathcal{W}_2(E)} \int W_2^2(\mu, \nu) d\mathbb{P}_j(\nu) = \arg \min_{\mu \in \mathcal{W}_2(E)} W_2^2(\mu, \mathcal{N}(-a_j, 1)) + W_2^2(\mu, \mathcal{N}(a_j, 1)).$$

El baricentro de $\mathbb{P}_j$ es nuevamente gaussiano:

$$\mu_j = \mathcal{N}(0, 1), \quad \forall j.$$

En la Figura 2.2 se muestra la evolución de las densidades correspondientes a $\mathbb{P}_j$ para distintos valores de a_j . Cada curva representa la mezcla

$$p_j(x) = \frac{1}{2}\varphi(x + a_j) + \frac{1}{2}\varphi(x - a_j),$$

donde φ es la densidad de $\mathcal{N}(0, 1)$. A medida que $a_j \rightarrow 0$, las dos componentes se fusionan y la mezcla converge hacia la densidad gaussiana estándar, que coincide con el baricentro.

Este experimento numérico ilustra el enunciado del Teorema 3: cuando $\mathbb{P}_j \rightarrow \mathbb{P}$ en $\mathcal{W}_2(\mathcal{W}_2(E))$, los baricentros μ_j también convergen (en este caso, permanecen constantes).




Fig. 2.2: Visualización del Teorema 3. Cada curva representa la mezcla $\frac{1}{2}\mathcal{N}(-a_j, 1) + \frac{1}{2}\mathcal{N}(a_j, 1)$ para distintos a_j . A medida que $a_j \rightarrow 0$, las dos gaussianas se acercan y el baricentro $\mathcal{N}(0, 1)$ (línea discontinua) se mantiene estable.

3. CUANTIZACIÓN DE MEDIDAS

La cuantización de medidas, como ya se mencionó, tiene como objetivo aproximar distribuciones de probabilidad mediante representaciones discretas más fácilmente manejables. En este enfoque, una medida arbitraria puede ser reemplazada por una combinación finita de puntos (los k *centros de cuantización*) acompañados de masas asociadas.

El objetivo práctico de esta teoría es estudiar el problema de cuantización que permite reducir la complejidad de una distribución, con la menor pérdida de información posible. Por ejemplo para la compresión de señales, el clustering o la reducción de dimensionalidad.

Además, durante el estudio de la cuantización no nos limitamos a una única medida: es posible extender estas ideas al caso de *varias distribuciones simultáneamente*, lo que lleva de manera natural a la noción de *baricentro de Wasserstein*. Esta extensión resulta interesante en contextos donde se busca encontrar una representación común que resuma múltiples fuentes de datos. Será introducida por primera vez y analizada en el capítulo siguiente.

Mientras tanto, se presentarán los aspectos teóricos fundamentales de la cuantización de medidas: *definiciones y nociones básicas* y *existencia y convergencia de cuantizadores óptimos*.

Para ello, dado un espacio (E, d, μ) , definiremos la cuantización de la medida μ por funciones cuantizadoras, conjuntos cuantizadores o k -means y, finalmente, hablaremos de cuantización por medidas de soporte finito. En particular, veremos como estas diferentes nociones se relacionan.

3.1. Definiciones y nociones básicas

3.1.1. Función cuantizadora y k -means

Para formalizar el problema de cuantización, debemos describir cómo una distribución continua puede aproximarse mediante un conjunto finito de puntos. La manera más natural de hacerlo es mediante funciones que, dado un punto x , lo reemplacen por uno de un número limitado de representantes. Esto motiva introducir el conjunto de todas las aplicaciones que “comprimen” el espacio en a lo sumo k va-

lores, lo que nos permitirá definir de manera precisa el error cometido al representar X mediante una versión discretizada.

Definición 5. Sea X una variable aleatoria en E con distribución μ . Sea $k \in \mathbb{N}$ y sea $\mathcal{F}_k$ el conjunto de todas las aplicaciones medibles de Borel

$$f : E \rightarrow E \quad \text{con } |f(E)| \leq k, \quad \text{donde } |A| \text{ denota el cardinal de } A.$$

Los elementos de $\mathcal{F}_k$ se llaman k -cuantizadores. Para cada $f \in \mathcal{F}_k$, $f(X)$ da una versión cuantizada de X .

Definición 6. El *error de cuantización k -ésimo de μ de orden p* se define como

$$\inf_{f \in \mathcal{F}_k} \mathbb{E}[d(X, f(X))^p]. \quad (3.1)$$

Un cuantizador $f^* \in \mathcal{F}_k$ se llama k -óptimo para μ de orden p si realiza el error de cuantización:

$$\mathbb{E}[d(X, f^*(X))^p] = \inf_{f \in \mathcal{F}_k} \mathbb{E}[d(X, f(X))^p].$$

Las funciones cuantizadoras están sumamente relacionadas con el problema de k -means, como veremos en lo que sigue.

Dados datos $\{x_1, \dots, x_n\} \subset \mathbb{R}^d$, o más generalmente, en un espacio métrico (E, d) , el objetivo de k -means es encontrar k centros $a_1, \dots, a_k$ que minimicen el costo

$$\frac{1}{n} \sum_{i=1}^n \min_{1 \leq j \leq k} d(x_i, a_j)^2,$$

donde cada punto se asigna al centro más cercano. Este procedimiento produce una partición del espacio en regiones y una discretización óptima, en promedio, de los datos originales. Así, k -means puede verse como una forma particular de cuantización, donde los centros representan los valores discretos que sustituyen a los datos originales. Podemos establecer formalmente esta relación en el siguiente lema:

Lema 1. Para $k \in \mathbb{N}$ fijo, buscar un cuantizador k -óptimo es equivalente al problema de k -means. En particular,

$$\inf_{\substack{\alpha \subset E \\ |\alpha| \leq k}} \mathbb{E} d(X, \alpha)^p = \inf_{f \in \mathcal{F}_k} \mathbb{E}[d(X, f(X))^p], \quad (3.2)$$

donde $d(x, \alpha) = \min_{a \in \alpha} d(x, a)$ para todo conjunto α finito. Usaremos $V(k, \mu)$ para denotar las magnitudes presentadas en (3.2).

Demostración. Para $f \in \mathcal{F}_k$, sea $\alpha = f(E)$ y $A_a = \{f(X) = a\}$, $a \in \alpha$. Entonces

$$\begin{aligned} \mathbb{E}[d(X, f(X))^p] &= \sum_{a \in \alpha} \int_{A_a} d(x, a)^p dP(x) \\ &\geq \sum_{a \in \alpha} \int_{A_a} \min_{b \in \alpha} d(x, b)^p dP(x) = \mathbb{E} \min_{b \in \alpha} d(X, b)^p = \mathbb{E} d(X, \alpha)^p. \end{aligned}$$

Recíprocamente, para $\alpha \subset E$ con $|\alpha| \leq k$, sea $\{A_a : a \in \alpha\}$ una partición de Voronoi de E respecto a α y sea $f = \sum_{a \in \alpha} a \mathbf{1}_{A_a}$ su correspondiente función de Voronoi. Entonces $f \in \mathcal{F}_k$ y

$$\mathbb{E} d(X, \alpha)^p = \mathbb{E} \min_{a \in \alpha} d(X, a)^p = \sum_{a \in \alpha} \int_{A_a} d(x, a)^p dP(x) = \mathbb{E}[d(X, f(X))^p] \quad (3.3)$$

□

Notar que la ultima desigualdad muestra que para toda partición existe una función tal que la perdida de la función coincide con la pérdida de la partición.

Para el tipo de espacios con el que trabajamos en esta tesis, el Teorema 4.12 del libro "Foundatios of Quantization por Probability Distributions" demuestra la existencia de un conjunto de cuantización minimizante. Junto con la ecuación 3.3, muestran que la respetiva función de Voronoi también es una función minimizante.

Más aún, toda función minimizante define un conjunto cuantizador minimizante mediante su imagen.

3.1.2. Cuantizando medidas

Por otro lado, un k -*cuantizador* de los ya definidos, puede asociarse con una medida de probabilidad soportada en a lo sumo k puntos.

Definición 7. Sea (E, d, μ) un espacio métrico, para $k \geq 1$, se define $\mathcal{M}_k$ como el conjunto de medidas de probabilidad en E con soporte de a lo sumo k puntos. O sea,

$$\mathcal{M}_k = \left\{ \nu = \sum_{i=1}^k \lambda_i \delta_{x_i} : x_i \in E, \lambda_i \geq 0, \sum_{i=1}^k \lambda_i = 1 \right\}.$$

Es decir, el conjunto de todas las medidas cuya masa está concentrada en no más de k puntos. En este contexto, un k -cuantizador de una medida μ es una medida $\mu_k \in \mathcal{M}_k$ que aproxima a μ en el sentido de Wasserstein.

Decimos que $\mu_k^* \in \mathcal{M}_k$ es un cuantizador óptimo para μ si:

$$\ell(\mu_k^*; \mu) := \inf_{\mu_k \in \mathcal{M}_k} \ell(\mu_k; \mu)$$

donde

$$\ell(\mu_k; \mu) := W_p(\mu_k, \mu).$$

Es decir, μ_k^* es una medida concentrada en a lo sumo k puntos que *más cerca esta* de μ , con respecto a W_p , la distancia de Wasserstein de orden p .

El Lema 3.4 de [6] establece el siguiente resultado que relaciona tanto el error de cuantización para cuantización mediante medidas con el error asociado a conjuntos cuantizadores, como el error de estos conjuntos con el de las funciones cuantizadoras.

Lema 2. *Sea $\mu \in \mathcal{W}_p(E)$. Entonces, tenemos que*

$$\inf_{\mu_k \in \mathcal{M}_k} W_p^p(\mu_k, \mu) = \inf_{\substack{\alpha \subset E \\ |\alpha| \leq k}} \mathbb{E} d(X, \alpha)^p = \inf_{f \in \mathcal{F}_k} \mathbb{E} [d(X, f(X))^p], \quad (3.4)$$

3.2. El cuantizador como medida imagen μf^{-1}

Para conectar la función de cuantización con una medida en $\mathcal{M}_k$, resulta conveniente describir al cuantizador mediante la medida imagen μf^{-1} . En este enfoque, la función f asigna a cada punto del espacio uno de los k valores, y esta asignación induce una medida soportada en esos puntos. Esta observación nos permite afirmar el siguiente resultado que vincula un f cuantizador óptimo (def. 5) con una medida óptima (def. 7) en $\mathcal{M}_k$.

Teorema 4. *Cada cuantizador de nivel k óptimo, f , para una medida $\mu \in \mathcal{W}_p(E)$ define una medida óptima $\nu_k^* \in \mathcal{M}_k$ como*

$$\nu_k^* := \mu f^{-1}. \quad (3.5)$$

Demostración. Si f es óptimo entonces es una función de Voronoi y para esta funciones vale la siguiente igualdad

$$W_p^p(\mu, \mu f^{-1}) = E(d^p(X, f(X)))$$

Además, como f es óptimo vale que $E(d^p(X, f(X))) = V(k, p)$ y, usando el resultado establecido en el Lema 2, concluimos que la medida μf^{-1} también es óptima. $\square$

Por otro lado, sea $\mu_k^* \in \mathcal{M}_k$ tal que $W_p(\mu_k^*, \mu) = V(k, \mu)$. Detonando con α al soporte de μ_k^* y considerando una partición de Voronoi $\{A_1, \dots, A_k\}$ de E asociada a $\alpha = \{a_1, \dots, a_k\}$, tenemos que $g = \sum_{i=1}^k a_i I_{A_i}$ es un cuantizador óptimo. Más aún, α es solución al problema de k -means.

En conclusión, hemos establecido una correspondencia entre los tres problemas planteados: dada una solución para cualquiera de ellos, es posible construir una solución para cualquiera de los otros dos.

3.3. Convergencia de cuantizadores óptimos

Una vez garantizada la existencia de cuantizadores óptimos para cada nivel k , podemos preguntarnos sobre su comportamiento asintótico. En aplicaciones prácticas como en compresión, simulación numérica o aproximación de medidas complejas mediante discretizaciones finitas, no solo interesa saber que tales cuantizadores existen, sino también comprender si la calidad de la aproximación mejora sistemáticamente al incrementar el número de puntos. Estudiar la convergencia de cuantizadores óptimos nos permite analizar en qué sentido las discretizaciones óptimas μ_k^* se aproximan a la medida original μ cuando el nivel de cuantización crece.

Si logramos mostrar que una medida puede ser aproximada arbitrariamente bien mediante una discretización, entonces podemos justificar que el proceso de cuantización permite aproximar medidas arbitrarias con precisión arbitraria y, por tanto, sostiene teóricamente muchos algoritmos basados en cuantización. Veamos el siguiente resultado que, efectivamente, prueba lo mencionado:

Teorema 5. *Dado E un espacio completo y separable, sea $\mu_k^* \in \mathcal{M}_k$ un cuantizador óptimo para $\mu \in \mathcal{W}_p(E)$. Luego, $\ell(\mu_k^*; \mu) \rightarrow 0$ cuando $k \rightarrow \infty$. Es decir,*

$$\lim_{k \rightarrow \infty} W_p(\mu, \mu_k^*) = 0.$$

Además, como la convergencia en W_p implica convergencia débil, obtenemos también $\mu_k^* \rightharpoonup \mu$ (ver teo. 1).

Demostración. La demostración del lema 5 esta basada en la demostración hecha en el capítulo 6 del libro "Foundations of Quantization for Probability Distributions" [6]

Sea $\{z_1, z_2, \dots\}$ un subconjunto numerable y denso en E . Entonces

$$E \subset \bigcup_{k \in \mathbb{N}} B\left(z_k, \left(\frac{\varepsilon}{2}\right)^{\frac{1}{p}}\right). \quad (1)$$

Por lo tanto, existe una partición boreliana $\{A_k\}_{k \in \mathbb{N}}$ de E con $A_k \subset B\left(z_k, \left(\frac{\varepsilon}{2}\right)^{\frac{1}{p}}\right)$ para todo k .

Como

$$\int_E d(x, x_0)^p d\mu(x) < \infty,$$

podemos tomar k suficientemente grande de modo que

$$\sum_{n > k} \int_{A_n} d(x, x_0)^p d\mu(x) \leq \frac{\varepsilon}{2}. \quad (2)$$

Si definimos la siguiente partición $A_1 \dots A_k, \tilde{A}_k$ donde $\tilde{A}_k$ es $\bigcup_{n > k} A_n$. Podemos tomar $g = \sum_{m=1}^k z_m \mathbf{1}_{A_m} + x_0 \mathbf{1}_{\tilde{A}_k}$ y definir la siguiente medida

$$\mu g^{-1} = \nu = \sum_{m=1}^k \delta_{z_m} \mu(A_m) + \mu(\tilde{A}_k) \delta_{x_0}.$$

Entonces,

$$W_p^p(\mu, \mu g^{-1}) \leq E(d(X, g(X))) = \sum_{i=1}^k \int_{A_i} d^p(x, a_i) d\mu + \int_{\tilde{A}_k} d^p(x, x_0) d\mu$$

Por (1) y (2),

$$W_p^p(\mu, \mu_k^*) \leq \varepsilon.$$

Como $\varepsilon > 0$ es arbitrario, concluimos que

$$\lim_{k \rightarrow \infty} \ell(\mu_k^*; \mu) = 0.$$

□

El resultado anterior es interesante pues significa que toda medida en $W_p(E)$ puede aproximarse arbitrariamente bien por medidas con soporte finito. Es decir,

las medidas de soporte finito son densas en $W_p(E)$:

$$\bigcup_{k \geq 1} \mathcal{M}_k \text{ es denso en } (W_p(E), W_p).$$

En términos prácticos, la propiedad de densidad proporciona una justificación teórica para aquellos métodos que, como en transporte óptimo, aprendizaje automático, simulación o compresión de datos, trabajan con discretizaciones de medidas continuas. En muchos de estos problemas se asume, por intuición o justificación práctica, que las aproximaciones mejoran al aumentar el número de datos. La teoría de cuantización óptima formaliza esta idea, garantizando que el error de aproximación converge a cero a medida que crece el tamaño del soporte. Esto permite reemplazar un problema complejo e infinito por uno finito y manejable, reduciendo el costo computacional, con la seguridad de que la solución discreta puede acercarse tanto como se desee a la solución real.

4. CUANTIZACIÓN CONJUNTA DE MEDIDAS

La teoría de cuantización hasta ahora mencionada esta enfocada en la discretización óptima de una única distribución de probabilidad μ . Sin embargo, la complejidad de muchos problemas del mundo real nos plantea la necesidad de manejar múltiples medidas simultáneamente.

Ante este problema, donde los datos emergen de distintas fuentes, poblaciones o condiciones, surge la pregunta decómo construir una representación discreta única que sea capaz de aproximar a todas estas distribuciones de forma conjunta y eficiente.

Sea $\{\mu_1, \mu_2, \dots, \mu_N\}$ un conjunto de medidas definidas sobre un espacio métrico E , una posibilidad es cuantizar cada distribución de manera independiente. Sin embargo, al igual que en el caso del baricentro, podemos intentar construir una representación discreta común para todas ellas.

Proponemos entonces una nueva perspectiva: considerar una *cuantización conjunta* de las medidas. Es decir, buscamos una única medida discreta que actúe como un resumen representativo del conjunto completo. Esta representación común no solo debe simplificar el procesamiento posterior de los datos, sino también aproximar simultáneamente a cada una de las distribuciones originales de la mejor manera posible.

Desde el punto de vista teórico, la cuantización conjunta está estrechamente relacionada con el problema del *baricentro de Wasserstein*. Ambos enfoques buscan construir una representación común que respete la estructura geométrica del espacio de distribuciones y minimice, de manera adecuada, la distancia entre ellas.

A continuación, formalizaremos la definición de nuestra propuesta de cuantización conjunta de medidas y analizaremos los resultados relativos a su existencia y convergencia.

4.1. Cuantización conjunta de medidas

En esta sección introducimos por primera vez el concepto de cuantización conjunta de medidas. Comenzaremos estudiando el caso más simple, donde buscamos una representación discreta común para dos medidas dadas. A partir de esta formulación, generalizaremos el problema al caso de un número arbitrario N de medidas. Finalmente, extenderemos estas ideas para aproximar no solo un conjunto finito de

distribuciones, sino también una medida de probabilidad definida sobre el espacio $W_p(E)$.

Definición 8. El *error de cuantización k -ésimo de orden p* para dos medidas $\mu_1, \mu_2 \in W_p(E)$ se define como

$$\inf_{\mu_k \in \mathcal{M}_k} \frac{1}{2} W_p^p(\mu_k, \mu_1) + \frac{1}{2} W_p^p(\mu_k, \mu_2). \quad (4.1)$$

y lo notamos como $V(k; \mu_1, \mu_2)$

Decimos que $\mu_k^* \in \mathcal{M}_k$ es un cuantizador óptimo para μ_1 y μ_2 si:

$$\ell(\mu_k^*; \mu_1, \mu_2) := \inf_{\mu_k \in \mathcal{M}_k} \ell(\mu_k; \mu_1, \mu_2)$$

donde

$$\ell(\nu; \mu_1, \mu_2) := \frac{1}{2} W_p^p(\nu, \mu_1) + \frac{1}{2} W_p^p(\nu, \mu_2).$$

Surge de manera natural la pregunta acerca del comportamiento límite de estas aproximaciones. Es decir, si consideramos una sucesión de cuantizadores conjuntos $\{\mu_k\}_{k \geq 1}$ con número de puntos creciente, resulta razonable preguntarse hacia qué medida debería converger dicha sucesión. La primera hipótesis fue que el límite es precisamente el baricentro de Wasserstein de μ_1 y μ_2 . Esta conexión proporciona una interpretación geométrica clara del problema y justifica el estudio detallado de la cuantización conjunta como un método de aproximación del baricentro.

Luego de plantear esta hipótesis es fácil plantearse una cuestión adicional: si la cuantización conjunta parece converger al baricentro de Wasserstein, entonces ¿son realmente diferentes los problemas de cuantizar el baricentro y de buscar una cuantización conjunta de las medidas iniciales? Si ambos procedimientos fueran equivalentes, la cuantización conjunta no aportaría nueva información y su estudio sería innecesario. Sin embargo, esta equivalencia no es evidente. Por esto estudiaremos esta pregunta y veremos, mediante dos ejemplos, que la cuantización del baricentro de dos medidas no coincide con el k -cuantizador conjunto de dichas medidas.

Consideramos el baricentro entre μ_1 y μ_2 de la siguiente manera:

$$\mu^* = \arg \min_{\mu} \frac{1}{2} W_p^p(\mu, \mu_1) + \frac{1}{2} W_p^p(\mu, \mu_2) = \arg \min_{\mu} \ell(\mu; \mu_1, \mu_2).$$

La cuantización conjunta o el *cuantizador simultáneo*:

$$Q_k^* = \arg \min_{\mu_k \in \mathcal{M}_k} \ell(\mu_k; \mu_1, \mu_2)$$

y el *cuantizador del baricentro* μ^* :

$$V_k^* = \arg \min_{\mu_k \in \mathcal{M}_k} W_p^p(\mu_k, \mu^*) = \arg \min \ell(\mu_k; \mu^*) \quad (4.2)$$

Queremos estudiar de que manera se relaciona V_k^* , el cunatizador del baricentro, con Q_k^* , el cuantizador simultaneo. Veamos en los ejemplos que, en general, estos objetos no coinciden.

Ejemplo 3. Tomemos $(\mathbb{R}, \|\cdot\|)$ y W_2 con

$$\mu_1 = \delta_0, \quad \mu_2 = \frac{1}{2}\delta_0 + \frac{1}{2}\delta_2.$$

Y consideremos siempre el baricentro cuyo tamaño de soporte es 1.

Si buscamos el cuantizador simultáneo:

$$Q_1^* = \arg \min \left[|x| + \left(\frac{1}{2}x^2 + \frac{1}{2}(x-2)^2 \right)^{1/2} \right].$$

Como el mínimo se alcanza en cero, $Q_1^* = \delta_0$.

Buscamos ahora el baricentro:

$$\mu^* = \arg \min_{\mu} \ell(\mu).$$

Sean F_{μ_1}, F_{μ_2} las funciones de distribución acumulada de μ_1, μ_2 . Por el teorema de Brenier (creo), el transporte óptimo viene dado por

$$T(x) = F_{\mu}^{-1} \left(\frac{F_{\mu_1}(x) + F_{\mu_2}(x)}{2} \right).$$

Donde

$$F_{\mu}^{-1}(t) := \inf \{x \in \mathbb{R} \mid F_{\mu}(x) \geq t\}, \quad t \in (0, 1).$$

Para $\mu_1 = \delta_0$, se tiene

$$F_{\mu_1}^{-1}(\tau) = 0, \quad \text{con } 0 < \tau \leq 1,$$

y para $\mu_2 = \frac{1}{2}\delta_0 + \frac{1}{2}\delta_2$,

$$F_{\mu_2}^{-1}(\tau) = \begin{cases} 0, & 0 < \tau \leq \frac{1}{2}, \\ 2, & \frac{1}{2} < \tau \leq 1. \end{cases}$$

De aquí se obtiene que

$$F_{\nu}^{-1}(\tau) = \frac{1}{2}F_{\mu_1}^{-1}(\tau) + \frac{1}{2}F_{\mu_2}^{-1}(\tau) = \begin{cases} 0, & 0 < \tau \leq \frac{1}{2}, \\ 1, & \frac{1}{2} < \tau \leq 1. \end{cases}$$

Por lo tanto,

$$\mu^* = \frac{1}{2}\delta_0 + \frac{1}{2}\delta_1.$$

Busquemos el cuantizador del baricentro,

$$V_1^* = \arg \min_{\nu \in M_1} \left[\left(\frac{1}{2}x^2 + \frac{1}{2}(x-1)^2 \right)^{1/2} \right]$$

Obtenemos que el mínimo se alcanza en $\frac{1}{2}$, entonces $V_1^* = \delta_{\frac{1}{2}}$. Finalmente, $V_1^* =$

$$\delta_{\frac{1}{2}} \neq \delta_0 = Q_1^*.$$

Ejemplo 4. Tomemos $(\mathbb{R}, \|\cdot\|)$ y W_2 con

$$\mu_1 = \mathcal{N}(-1, 1), \quad \mu_2 = \mathcal{N}(1, 1)$$

Y consideremos siempre el cuantizador cuyo tamaño de soporte es 2.

Para este caso, el baricentro es

$$\mu^* = \mathcal{N}(0, 1)$$

Ahora, busquemos el cuantizador óptimo soportado en dos puntos para el baricentro:

$$V_n^* = \arg \min_{a_1, a_2 \in \mathbb{R}} \mathbb{E} \left[\min \{ (X - a_1)^2, (X - a_2)^2 \} \right]$$

Por simetría (ver apéndice), se deduce que $a_1 = -a_2$. Fijamos $a_2 > 0$.

$$V_n^* = \mathbb{E}[(X - a_1)^2 \mathbf{1}_{\{X \leq 0\}}] + \mathbb{E}[(X - a_2)^2 \mathbf{1}_{\{X > 0\}}].$$

Derivando respecto de a_2 :

$$0 = \frac{\partial}{\partial a_2} \mathbb{E}[(X - a_2)^2 \mathbf{1}_{\{X > 0\}}] = \mathbb{E}[2(X - a_2)(-1) \mathbf{1}_{\{X > 0\}}] = \mathbb{E}[2(a_2 - X) \mathbf{1}_{\{X > 0\}}]$$

$$a_2 \mathbb{P}(X > 0) = \mathbb{E}[X \mathbf{1}_{\{X > 0\}}].$$

Por lo tanto,

$$a_2 = \frac{\mathbb{E}[X \mathbf{1}_{\{X > 0\}}]}{\mathbb{P}(X > 0)} = \mathbb{E}[X \mid X > 0].$$

Sabemos que

$$\mathbb{E}[X \mid X > 0] = \frac{\int_0^\infty x \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx}{\mathbb{P}(X > 0)}.$$

Como $\mathbb{P}(X > 0) = \frac{1}{2}$, se obtiene

$$\mathbb{E}[X \mid X > 0] = \frac{1}{1/2} \cdot \frac{1}{\sqrt{2\pi}} \int_0^\infty x e^{-x^2/2} dx = \sqrt{\frac{2}{\pi}} \approx 0,7979.$$

Por lo tanto:

$$a_1 = -\sqrt{\frac{2}{\pi}}, \quad a_2 = \sqrt{\frac{2}{\pi}}.$$

Si buscamos el cuantizador simultaneo:

$$Q_n^* = \arg \min_{a_1, a_2 \in \mathbb{R}} \left\{ \mathbb{E}[\min\{(X - a_1)^2, (X - a_2)^2\}] + \mathbb{E}[\min\{(Y - a_1)^2, (Y - a_2)^2\}] \right\}.$$

Por el mismo principio de simetría respecto del cero, buscamos minimizar la siguiente expresión (para el caso $X \leq 0$ es análogo):

$$\mathbb{E}[(X - a_2)^2 \mathbf{1}_{\{X > 0\}}] + \mathbb{E}[(Y - a_2)^2 \mathbf{1}_{\{Y > 0\}}].$$

Derivando e igualando a cero para obtener el mínimo:

$$a_2(\mathbb{P}(X > 0) + \mathbb{P}(Y > 0)) = \mathbb{E}[X \mathbf{1}_{\{X > 0\}}] + \mathbb{E}[Y \mathbf{1}_{\{Y > 0\}}].$$

Así,

$$a_2 = \frac{\mathbb{E}[X \mathbf{1}_{\{X > 0\}}] + \mathbb{E}[Y \mathbf{1}_{\{Y > 0\}}]}{\mathbb{P}(X > 0) + \mathbb{P}(Y > 0)}.$$

Donde:

$$\mathbb{P}(X > 0) = 0,1587, \quad \mathbb{P}(Y > 0) = 0,8413,$$

$$\mathbb{E}[X \mathbf{1}_{\{X > 0\}}] = 0,0834, \quad \mathbb{E}[Y \mathbf{1}_{\{Y > 0\}}] = 1,0834.$$

Por lo tanto,

$$a_2 = \frac{0,0834 + 1,0834}{0,1587 + 0,8413} \approx 1,1666,$$

y

$$a_1 = -a_2 \approx -1,1666.$$

Finalmente, los cuantizadores optimos no coinciden.

A partir de estos ejemplos concluimos que, en general, el cuantizador del baricentro no coincide con el cuantizador conjunto. Esto motiva a continuar con la siguiente pregunta: aunque no sean idénticos para un k fijo, ¿se aproxima el cuantizador conjunto al baricentro cuando aumenta el número de puntos? En otras palabras,

$$Q_k^* \xrightarrow[k \rightarrow \infty]{D} \mu^*,$$

donde μ^* denota el baricentro de μ_1 y μ_2 .

Teorema 6. Sean μ_1, μ_2 dos medidas de probabilidad. Sea μ^* el único baricentro de μ_1 y μ_2 en el sentido de la distancia de Wasserstein W_p . Sea además Q_k^* un cuantizador óptimo simultáneo de μ_1 y μ_2 , soportado en a lo sumo k puntos (definido previamente). Entonces,

$$Q_k^* \xrightarrow[k \rightarrow \infty]{D} \mu^*.$$

Demostración. Es suficiente con probar que

$$W_p^p(Q_k^*, \mu^*) \xrightarrow[k \rightarrow \infty]{} 0.$$

Consideremos, V_k^* definifo en 4.2. Del Teorema 5 sabemos que $V_k^* \rightarrow \mu^*$. Entonces

$$\ell(\mu^*; \mu_1, \mu_2) \leq \ell(Q_k^*; \mu_1, \mu_2) \leq \ell(V_k^*; \mu_1, \mu_2) \rightarrow \ell(\mu^*; \mu_1, \mu_2) \quad y$$

$$\ell(Q_k^*; \mu_1, \mu_2) \rightarrow \ell(\mu^*; \mu_1, \mu_2).$$

Si logramos probar que

$$\ell(Q_k^*; \mu_1, \mu_2) \rightarrow \ell(\mu^*; \mu_1, \mu_2) \quad \Rightarrow \quad W_p^p(Q_k^*, \mu^*) \rightarrow 0$$

obtenemos que

$$Q_k^* \rightarrow \mu^*.$$

Veamos que esto efectivamente sucede en el siguiente teorema (teo. 7). □

Teorema 7. Sea (E, d) un espacio métrico polaco. Sea $p \geq 1$ y sea $\mathbb{P} \in \mathcal{W}_p(\mathcal{W}_p(E))$. Sea $Q_k^* \in \mathcal{M}_k$ un cuantizador k -óptimo. Supongamos que existe un único minimizador de $\ell(\mu; \mathbb{P})$ en $\mathcal{W}_p(E)$ y lo denotamos μ^* . Entonces,

$$\ell(Q_k^*; \mathbb{P}) = \mathbb{E}_{\mu \sim \mathbb{P}} W_p(Q_k^*, \mu) \rightarrow \mathbb{E}_{\mu \sim \mathbb{P}} W_p(\mu^*, \mu) = \ell(\mu^*; \mathbb{P}) \Rightarrow Q_k^* \rightarrow \mu^*$$

La idea principal de la demostración es que si μ^* es único baricentro de $\mathbb{P}$, cualquier límite de una subsucesión de Q_k^* converge y el límite debe coincidir con μ^* .

Primero veamos que la sucesión Q_k^* es tight

Demostración. Fijemos $x_0 \in E$. Para cualquier $\nu \in \mathcal{W}_p(E)$ y $\mu \in \mathcal{W}_p(E)$ vale la desigualdad triangular para W_p :

$$W_p(\nu, \delta_{x_0}) \leq W_p(\nu, \mu) + W_p(\mu, \delta_{x_0}).$$

Tomando esperanza respecto a $\mu \sim \mathbb{P}$, se obtiene

$$W_p(\nu, \delta_{x_0}) \leq \mathbb{E}_\mu[W_p(\nu, \mu)] + \mathbb{E}_\mu[W_p(\mu, \delta_{x_0})] = \mathbb{E}_\mu[W_p(\nu, \mu)] + C,$$

donde

$$C = \mathbb{E}_\mu[W_p(\mu, \delta_{x_0})] < \infty \quad (\text{por la hipótesis } \mathbb{P} \in \mathcal{W}_p(\mathcal{W}_p(E))).$$

Aplicando esto a $\nu = Q_k^*$ obtenemos

$$W_p(Q_k^*, \delta_{x_0}) \leq \ell(Q_k^*; \mathbb{P}) + C = \mathbb{E}_\mu[W_p(Q_k^*, \mu)] + C \leq \mathbb{E}_\mu[W_p(Q_1, \mu)] + C,$$

para cualquier $Q_1 \in \mathcal{W}_p(E)$ fijo (pues $\ell(Q_k^*; \mathbb{P}) \leq \mathbb{E}_\mu[W_p(Q_1, \mu)]$ por ser Q_k^* óptimo y $\ell(Q_k^*; \mathbb{P}) \leq \ell(Q_j^*; \mathbb{P}) \forall j \leq k$).

En consecuencia, los momentos p -ésimos de Q_k^* están uniformemente acotados:

$$\sup_k W_p(Q_k^*, \delta_{x_0}) < \infty.$$

□

Demostración. (Teorema 7) Como la sucesión Q_k^* es tight. Existe una subsucesión $Q_{k_j}^*$ y $\nu \in \mathcal{W}_p(E)$ tales que $Q_{k_j}^* \rightarrow \nu$ cuando $j \rightarrow \infty$. Como W_p es continua en $\mathcal{W}_p(E)$, $\mathbb{E}[W_p]$ es continua en $\mathcal{W}_p(\mathcal{W}_p(E))$. Luego,

$$\mathbb{E}_{\mu \sim \mathbb{P}} W_p(\nu, \mu) = \lim_{j \rightarrow \infty} \mathbb{E}_{\mu \sim \mathbb{P}} W_p(Q_{k_j}^*, \mu) = \lim_{j \rightarrow \infty} \ell(Q_{k_j}^*; \mathbb{P}) = \ell(\mu; \mathbb{P})$$

Así, ν es minimizador de ℓ . Como asumimos que es único, ν debe coincidir con μ^* .

Esto quiere decir que toda subsucesión convergente de (Q_k^*) tiene límite μ^* . Como la sucesión es relativamente compacta, cualquier subsecuencia posee a su vez una subsucesión convergente; por lo tanto, todos los puntos de acumulación de (Q_k^*) coinciden con μ^* . En consecuencia, $Q_k^* \rightarrow \mu^*$ en W_p . $\square$

Luego de analizar el caso de dos medidas, podemos extender la teoría al caso de un conjunto finito de distribuciones. Ahora, el objetivo es encontrar una única medida discreta que actúe como una representación común de todas ellas. Incluso, podemos ponderar su contribución mediante coeficientes λ_i . Entonces, si ahora consideramos la cuantización simultanea de N medidas, el error se define como:

$$\ell(\nu; \mu_1 \dots \mu_n) = \min_{\nu \in \mathcal{M}_k} \sum_{i=1}^N \lambda_i W_p(\nu, \mu_i),$$

el baricentro de N medidas como:

$$\mu^* = \arg \min_{\nu \in W_p(E)} \sum_{i=1}^N \lambda_i W_p(\nu, \mu_i) = \arg \min \ell(\nu; \mu_1 \dots \mu_n),$$

la cuantización conjunta o el *cuantizador simultáneo* como:

$$Q_k^* = \arg \min_{\mu_k \in \mathcal{M}_k} \ell(\mu_k; \mu_1 \dots \mu_n)$$

y el *cuantizador del baricentro* μ^* como:

$$V_k^* = \arg \min \ell(\mu_k; \mu^*)$$

Para este caso, el lema 2 que conduce a la existencia de cuantizadores y el teorema 6 se pueden extender facilmente.

Finalmente, en lugar de trabajar con un conjunto discreto de distribuciones, consideramos ahora una medida de probabilidad definida sobre el espacio métrico $\mathcal{W}_p(E)$. En este contexto, el objetivo es construir un cuantizador de grado k que proporcione una representación discreta para toda la distribución $\mathbb{P}$ sobre medidas. Si E es un espacio métrico completo, separable y y Heine Borel, entonces los resultados descriptos anteriormente se podrían extender a este espacio.

5. APLICACIONES

En los capítulos anteriores se presentó el marco teórico de la cuantización óptima de medidas, mostrando su relación con el problema de k -means y su formulación, tanto clásica como en sus extensiones a 2 y N medidas. En el capítulo de preliminares se introdujeron conceptos fundamentales, como la distancia de Wasserstein y el baricentro de Wasserstein, que constituyen la base necesaria para estudiar la cuantización. Posteriormente, se profundizó en la teoría de cuantización de medidas: se definieron los cuantizadores, se estudiaron cuestiones de existencia y convergencia, y se extendieron estos conceptos a la cuantización conjunta de medidas. Estos resultados proporcionan las herramientas esenciales para analizar y aplicar métodos de cuantización en distintos contextos, que serán presentados en este capítulo.

5.1. Conditional flow matching for generative modeling


Los modelos generativos son algoritmos de aprendizaje profundo orientados a estimar y muestrear distribuciones de datos desconocidas o a generar datos sintéticos de una distribución en particular. Uno de los métodos en auge actualmente se basa en aproximar una distribución desconocida de datos $p_{\text{data}}(x)$ construyendo una transformación que lleve muestras de una distribución base simple (por ejemplo, una normal estándar) hacia muestras que sigan la distribución de los datos.

En la práctica, estos métodos suelen basarse en muestreos aleatorios del conjunto de datos para reducir el costo computacional asociado al gran volumen de información. En las secciones siguientes analizaremos qué es el problema de *Conditional Flow Matching*, revisaremos las implementaciones más utilizadas para resolver estos problemas y exploraremos cómo la cuantización conjunta puede integrarse para mejorar la eficiencia y la estabilidad de los modelos generativos.

5.1.1. Flow matching

Sea $\mathbb{R}^d$ el espacio de datos, con puntos de datos $x = (x^1, \dots, x^d) \in \mathbb{R}^d$, consideremos dos distribuciones de probabilidad:

$$x_0 \sim p(x), \quad x_1 \sim q(x),$$



(a) Ejemplo: una muestra X_0 extraída de p (ruido) y su correspondiente X_1 en q (imagen).

(b) Evolución intermedia p_t que transporta la distribución inicial p hacia la distribución objetivo q .

Fig. 5.1: Relación entre la trayectoria de densidades p_t y las muestras individuales X_0 y X_1 . Ilustración tomada de <https://ronaldyu.substack.com/p/an-intuitive-intro-to-flow-matching>.

donde p es una distribución simple (por ejemplo, $\mathcal{N}(0, I)$) y q representa la distribución de los datos reales. Podemos imaginar una transformación continua $(x_t)_{t \in [0,1]}$ que mueve las partículas desde p hasta q de acuerdo con un campo vectorial $u_t(x)$. Si conociéramos el campo $u_t(x)$, podríamos generar nuevas muestras integrando esta ecuación desde $t = 0$ hasta $t = 1$. En la práctica, $u_t(x)$ es desconocido y debe aprenderse a partir de los datos.

Entonces, si quisiéramos aprender una distribución de datos desconocida $q(x_1)$, de la cual sólo disponemos de muestras x_i , debemos aprender un flujo continuo que transforme una distribución de ruido simple conocida p_0 en una distribución objetivo p_1 que se aproxime a $q(x_1)$.

Para ello, se introduce una familia continua de distribuciones $\{p_t\}_{t \in [0,1]}$ que conecta suavemente $p_0 = p$ con $p_1 = q$. La idea es modelar cómo evoluciona una muestra x a lo largo del tiempo t , siguiendo un campo vectorial $u_t(x)$ que genera $p_t(x)$. Es decir, necesitamos entrenar un modelo que aprenda $u_t(x)$, la dirección que apunta de p_t a q en cualquier punto x .

Esto se logra minimizando la siguiente función de pérdida:

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{t \sim \mathcal{U}[0,1], p_t(x)} [\|u_{\theta_t}(x) - u_t(x)\|^2]. \quad (5.1)$$

donde θ define los parametros aprendibles del campo vectorial.

Sin embargo, en la práctica no conocemos de antemano cuáles deberían ser p_t ni

u_t y además no disponemos de una forma cerrada para el campo de velocidades que genere la trayectoria deseada. Por esto, se propuso construir p_t y u_t utilizando pares de muestras (x_0, x_1) estimando el flujo.

5.1.2. Construcción de p_t, u_t a partir de trayectorias de probabilidad condicionales y campos vectoriales

Una manera simple de construir una trayectoria de probabilidad objetivo es mediante una mezcla de trayectorias de probabilidad más simples. Dada una muestra de datos particular x_1 denotamos por $p_t(x|x_1)$ una *trayectoria de probabilidad condicional* tal que satisface $p_0(x|x_1) = p(x)$ en el tiempo $t = 0$, y diseñamos $p_1(x|x_1)$ en $t = 1$ como una distribución concentrada alrededor de $x = x_1$, por ejemplo, $p_1(x|x_1) = \mathcal{N}(x|x_1, \sigma^2 I)$, una distribución normal con media x_1 y desviación estándar suficientemente pequeña $\sigma > 0$. Ahora, si interpolamos linealmente entre p y x_1 , todas nuestras distribuciones intermedias p_t son gaussianas con varianza decreciente (ver fig. 5.2).




Fig. 5.2: Distribución marginal a x_1 . Ilustración tomada de <https://ronaldu.substack.com/p/an-intuitive-intro-to-flow-matching>.

Marginalizando las trayectorias de probabilidad condicional sobre $q(x_1)$ obtenemos la *trayectoria de probabilidad marginal*

$$p_t(x) = \int p_t(x|x_1)q(x_1) dx_1, \quad (5.2)$$

donde en particular, en el tiempo $t = 1$, la probabilidad marginal p_1 es una distribución mezcla que aproxima la distribución de datos q ,

$$p_1(x) = \int p_1(x|x_1)q(x_1) dx_1 \approx q(x). \quad (5.3)$$

También podemos definir un *campo vectorial marginal*, “marginalizando” sobre los campos vectoriales condicionales de la siguiente manera (asumimos $p_t(x) > 0$ para todo t y x):

$$u_t(x) = \int u_t(x|x_1) \frac{p_t(x|x_1)q(x_1)}{p_t(x)} dx_1, \quad (5.4)$$

donde $u_t(x|x_1) : \mathbb{R}^d \rightarrow \mathbb{R}^d$ es un campo vectorial condicional que genera $p_t(x|x_1)$.

5.1.3. Conditional flow matching

Debido a las integrales intratables en las definiciones de la trayectoria de probabilidad marginal y el campo vectorial (ecuaciones 5.2 y 5.4), es imposible computar u_t . Por eso, consideramos el siguiente objetivo de *Conditional Flow Matching* (CFM):

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t, x_1, x} [\|u_{\theta,t}(x) - u_t(x|x_1)\|^2], \quad (5.5)$$

donde $t \sim U[0, 1]$, $x_1 \sim q(x_1)$ y $x \sim p_t(x|x_1)$. A diferencia del objetivo FM, el objetivo CFM nos permite estimaciones imparciales simples siempre que podamos muestrear de $p_t(x|x_1)$ y computar $u_t(x|x_1)$, lo cual puede hacerse fácilmente ya que están definidos de manera individual para cada muestra.

Los objetivos FM (Ecuación 5.5) y CFM (Ecuación 5.5) tienen gradientes idénticos con respecto a θ . Esto significa que optimizar el objetivo CFM es equivalente a optimizar el objetivo FM. Simplemente necesitamos diseñar trayectorias de probabilidad condicional y campos vectoriales adecuados para aprender el objetivo.

5.1.4. Implementación

Recordando, el objetivo es aprender un campo de velocidades $u_{\theta,t}(x)$ que transforme de forma continua una distribución inicial p (ruido) en una distribución objetivo q (datos). En Conditional Flow Matching (CFM) se construyen trayectorias condicionadas $(X_t)_{t \in [0,1]}$ entre muestras $X_0 \sim p$ y $X_1 \sim q$, y se entrena la red para emular la velocidad de esas trayectorias.

En la práctica, el problema se resuelve muestRANDO aleatoriamente k puntos de la distribución $x_0 \sim p$ (ruido) y $x_1 \sim q$ (datos) en cada minibatch y se resuelve un problema de transporte óptimo (OT) discreto entre las muestras $\{x_0^i\}_{i=1}^k$ y $\{x_1^j\}_{j=1}^k$, es decir, se calcula el plan de transporte óptimo π^* entre los puntos y se emparejan los pares de acuerdo al plan óptimo. Luego se aplica la función de pérdida CFM. Finalmente, el OT se calcula sólo entre los k puntos de ruido y los k puntos de datos

dentro de cada minibatch.

El problema puede resolverse eficientemente con el algoritmo de Sinkhorn, con complejidad práctica $O(B^2)$ por iteración. Tras reemparejar usando el plan de transporte obtenido, la pérdida $\mathcal{L}_{\text{CFM}}$ se evalúa sobre los pares creados, lo que conduce a trayectorias más rectas y normalmente a menor varianza del estimador de gradiente.




Fig. 5.3: Ejemplo sintético de OT-CFM. Imagen tomada de las diapositivas “Regularized and Neural Approaches to Solve Optimal Transport” de Marco Cuturi (Escuela Deep Learning, 24 Oct. 2025).

La figura muestra el caso más simple y frecuente: la *interpolación lineal* entre X_0 y X_1 . Para $t \in [0, 1]$,

$$X_t = (1 - t)X_0 + tX_1, \quad X_0 \sim \mu_0, \quad X_1 \sim \mu_1. \quad (5.6)$$

La velocidad *verdadera* (condicional) a lo largo de esa recta es

$$u_t(x \mid X_1) = \frac{d}{dt}[(1 - t)X_0 + tX_1] = X_1 - X_0. \quad (5.7)$$

Observamos que, para la interpolación lineal, la velocidad es constante en t y no depende explícitamente de la posición intermedia X_t (sólo del par (X_0, X_1)). En implementaciones más generales u_t puede depender de t y de X_t .

Dado un modelo de velocidades $u_{\theta,t}(x)$, la pérdida típica empleada en CFM es una regresión cuadrática entre la velocidad predicha por la red y la velocidad condicional conocida:

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{T \sim \mathcal{U}(0,1), X_0 \sim \mu_0, X_1 \sim \mu_1} \left[\|u_{\theta,T}(X_T) - u_T(X_T \mid X_1)\|^2 \right]. \quad (5.8)$$

Para la interpolación lineal con (5.7), la pérdida se puede escribir de forma explícita como

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{T, X_0, X_1} \left[\left\| u_{\theta, T}((1-T)X_0 + TX_1, T) - (X_1 - X_0) \right\|^2 \right]. \quad (5.9)$$

Minimizar $\mathcal{L}_{\text{CFM}}$ fuerza a u_θ a predecir, en cada punto intermedio X_T y instante T , la velocidad que llevaría a X_0 a X_1 por la interpolación elegida.

Para resumir, el campo vectorial marginal $u_t(x)$ no se calcula evaluando explícitamente la integral de la eq. 5.4, la cual expresa que el campo en cada punto x es un *promedio ponderado* de todos los campos vectoriales condicionales $u_t(x | x_1)$ asociados a los posibles destinos x_1 . Si para un mismo punto intermedio x existen muchas trayectorias de transporte posibles, el campo marginal recoge la *dirección promedio* teniendo en cuenta cuán probable es cada trayectoria.




Fig. 5.4: Construcción del campo vectorial condicional. Ilustración tomada de <https://ronaldu.substack.com/p/an-intuitive-intro-to-flow-matching>.

El modelo se entrena para predecir el campo u_θ condicional en los puntos interpolados X_t , (las “flechas negras” de la fig. 5.4). Al repetir este procedimiento sobre una gran cantidad de pares (X_0, X_1) muestreados, la red observa todas las trayectorias posibles que pueden atravesar cada región del espacio. Como resultado, la red no aprende un campo determinista por cada par, sino que aprende el *promedio estadístico* de todas las direcciones compatibles con un punto x y un tiempo t . Dicho promedio coincide precisamente con la definición del campo marginal $u_t(x)$: la esperanza del campo condicional ponderada por la probabilidad de cada posible destino x_1 .

5.1.5. Consideraciones

El cálculo del plan óptimo en cada minibatch tiene una complejidad cuadrática en el tamaño del batch ($O(B^2)$), lo que puede resultar costoso. Además, las distribuciones de ruido y de datos pueden concentrar masa en regiones muy diferentes, lo que genera emparejamientos ruidosos o inestables en el transporte entre muestras individuales.

Hasta ahora, hemos asumido que los puntos utilizados en cada minibatch para calcular el transporte óptimo se seleccionan de manera aleatoria. Pero, ¿qué pasaría si en vez de usar aleatoriedad nos basamos en la teoría de cuantización para elegirlos?

Esta es precisamente nuestra propuesta. La motivación surge de lo discutido en secciones anteriores: la distancia de Wasserstein permite comparar distribuciones de manera más realista, porque no solo evalúa puntos individuales, sino también cómo se organizan en el espacio. Dicho de otro modo, incorpora la forma y la estructura geométrica de los datos, lo que ayuda a mitigar los problemas mencionados previamente.

Por eso, cuando queremos aproximar una distribución con un número reducido de muestras, es importante que esas muestras representen adecuadamente dicha estructura. La teoría de cuantización ofrece el marco teórico para construir estas representaciones compactas y bien distribuidas, lo que da fundamento a nuestra propuesta.

En este caso, la idea general es aproximar cada distribución mediante un conjunto discreto de muestras, centroides:

$$p_0 \approx \sum_{i=1}^{K_0} w_i^0 \delta_{c_i^0}, \quad p_1 \approx \sum_{j=1}^{K_1} w_j^1 \delta_{c_j^1},$$

donde $\{c_i^0\}$ y $\{c_j^1\}$ son los centroides obtenidos, por ejemplo, mediante k -means, y $\{w_i^0\}, \{w_j^1\}$ son pesos asociados a la frecuencia de cada clúster.

Sobre estas representaciones reducidas se resuelve un problema de transporte óptimo más pequeño, obteniendo un plan de transporte entre centroides en lugar de entre todas las muestras individuales. Además de los beneficios en cuanto a costo computacional, la cuantización es un tipo de regularización que evita que el modelo aprenda trayectorias ruidosas a partir de una selección de centroides que representan correctamente la distribución que se quiere modelar.

Además, proponemos que en lugar de tomar directamente k puntos de cada dis-

tribución para construir los emparejamientos, tomemos un enfoque más informado: primero tomamos una muestra más grande de tamaño $n \gg k$, y sobre esa muestra aplicamos un proceso de cuantización para obtener k centroides.

En algunos experimentos observamos que esta estrategia produce representaciones mucho más estables y cercanas a la distribución original que si simplemente elegimos k . En nuestro contexto, esto significa que los emparejamientos usados en el entrenamiento de OT-CFM reflejarían mejor la geometría de los datos y, por lo tanto, el modelo aprendería campos de velocidad más coherentes y consistentes.

En el ejemplo img. 5.5 mostramos cómo tomar una muestra grande de n puntos de la distribución original y luego aplicar cuantización permite obtener una mejor aproximación de la distribución que tomar directamente k puntos al azar.

En las imágenes, el caso etiquetado como *directa* corresponde al muestreo aleatorio simple de k puntos de la distribución, mientras que el caso *cuantizada* corresponde a tomar primero $n \gg k$ muestras y luego reducirlas a k centroides mediante cuantización (k -means). Puede observarse que la versión cuantizada conserva mejor la forma y la estructura de la distribución original, y siempre aproxima con menor error a la distribución verdadera. Además, el tamaño de los puntos en la representación cuantizada refleja el peso asignado a cada centroide, proporcional a la cantidad de muestras originales que agrupa, lo que permite capturar no solo la geometría sino también la densidad de la distribución.

Además de estas visualizaciones, decidimos hacer algunas implementaciones y mostrar cómo la cuantización es capaz de superar al muestreo aleatorio en al resolver el problema de *Conditional Flow Matching*. En primer lugar, entrenamos un modelo con el conjunto MNIST, donde observamos que el uso de cuantización mediante k -means o el muestreo aleatorio no producía diferencias significativas en el desempeño. Sin embargo, al repetir el procedimiento sobre el conjunto FashionMNIST, notamos que efectivamente aplicar k -means, tanto en su versión balanceada como sin balancear, mejoraba el error respecto al muestreo aleatorio (ver fig. 5.6).

La Figura 5.6 muestra cómo evoluciona el error de entrenamiento para diferentes tamaños de *batch-sizes*. En todos los casos, el esquema de muestreo cuantizado presenta una curva de descenso del *loss* igual o menor que el muestreo al azar, especialmente en los *batch-sizes* más pequeños. Además, observamos que usando tamaños de batch más pequeños y la cuantización, la *loss* es menor a la del muestreo al azar comparando para cualquier número de *batch-sizes*.

Sin bien es un problema no tan complejo, esto sugiere que la cuantización introduce una mejor representatividad de los datos dentro de cada minibatch beneficiando




Fig. 5.5: Comparación entre diferentes distribuciones de muestreo: uniforme, normal y anillo




Fig. 5.6: Evolución del *loss* a lo largo de las épocas para distintos valores de *batch_size*, comparando el muestreo al azar con el muestreo cuantizado.

al optimizador.

Por otro lado, surgió la pregunta de si sería posible obtener el mismo nivel de error utilizando una menor cantidad de muestras. Este aspecto resulta especialmente interesante, ya que implicaría una reducción en la complejidad computacional sin perjudicar la calidad del entrenamiento.




Fig. 5.7: Diferencia entre las curvas de entrenamiento bajo muestreo al azar y muestreo cuantizado para distintos valores de *batch size*. La curva muestra (azar – cuantizado), por lo que valores positivos indican que el enfoque cuantizado logra un *loss* menor en esa época.

La Figura 5.7 resume la diferencia punto a punto entre las trayectorias de entrenamiento de ambos métodos. Se observa que, para todos los valores de *batch size*, la diferencia tiende a ser mayor o igual a cero en casi todas las épocas, lo que indica que el esquema cuantizado mantiene un desempeño mejor. Para tamaños de lote pequeños, la diferencia es claramente más pronunciada, lo cual sugiere que la cuan-

tización atenúa la variabilidad inherente a minibatches reducidos evitando enfocar el entrenamiento en outliers

5.2. Aprendizaje federado

En esta sección mostramos tres problemas del FL donde la cuantización de medidas resulta especialmente útil: (i) la compresión de gradientes para reducir comunicación, (ii) la reducción de datos locales y su heterogeneidad mediante cuantización conjunta previa al entrenamiento, y (iii) el cálculo federado de distancias de Wasserstein, donde la cuantización conjunta ofrece una aproximación eficiente del baricentro.

5.2.1. Introducción

El **Aprendizaje Federado (FL)** es un enfoque de *Machine Learning* (ML) distribuido cuyo propósito es entrenar un modelo global utilizando datos dispersos en una multitud de dispositivos locales (clientes). Su característica es la preservación de la privacidad, ya que los clientes no comparten sus muestras de datos sin procesar con el servidor central.




Fig. 5.8: Federated Learning

Esto contrasta con el ML tradicional, que requiere agrupar todos los datos en un repositorio central. Si bien el entrenamiento centralizado ha impulsado grandes avances en la IA, genera preocupaciones críticas sobre la privacidad, la seguridad. FL ofrece una alternativa, manteniendo los datos sensibles localizados en el dispositivo del usuario. También reduce los costos computacionales y de almacenamiento asociados al entrenamiento centralizado.

Un procedimiento típico de FL consiste en un ciclo iterativo coordinado por un

servidor central y múltiples clientes participantes. Primero se realiza una actualización local. Los clientes utilizan sus datos privados para entrenar y actualizar sus versiones locales del modelo global. Luego, se realiza la agregación global, los parámetros actualizados se envían al servidor central, donde se agregan para producir la nueva versión mejorada del modelo global.

Si bien el FL se enfoca primariamente en el entrenamiento de modelos predictivos, existen escenarios prácticos donde el objetivo es computar una cantidad específica a partir de los datos distribuidos, en lugar de entrenar un predictor. Estos incluyen el cálculo de centros de datos para el *clustering* federado o la evaluación de la heterogeneidad entre los conjuntos de datos de los clientes, un factor crucial para el rendimiento de los modelos.

Principales problemas de Federated Learning

Bottleneck

Uno de los problemas es que este modelo, como la mayoría de los modelos de *Deep Learning*, es que suelen poseer una dimensión de parámetros d alta. La transmisión del vector de actualización completo, $\Delta \mathbf{w}_i \in \mathbb{R}^d$, en cada ronda o batch y por cada cliente genera costo de transmisión alto. Este costo de comunicación domina el tiempo total de entrenamiento del sistema, volviendo el FL inviable a gran escala. Esto se conoce como el cuello de botella de la comunicación [14].

Para solucionar o mitigar este problema se introducen técnicas de compresión. Sea $\Delta \mathbf{w}_i \in \mathbb{R}^d$ la actualización local (o gradiente) del cliente i en una ronda de comunicación. El objetivo de las técnicas de compresión es construir una representación comprimida tal que el tamaño sea mucho menor que d . Sin embargo, la pérdida de información introducida por la compresión no debería degradar significativamente la convergencia ni el rendimiento final del modelo global y, cuando sea posible, se preserve estructura de los datos y no sólo magnitudes individuales.

En lugar de enviar todo el vector $\Delta \mathbf{w}_i$, el cliente puede transmitir únicamente un subconjunto de componentes consideradas *importantes*, reduciendo la dimensión efectiva del mensaje. Alguno de los métodos son:

- **Top- k Sparsification:** se envían las k componentes de mayor magnitud.
- **Thresholding:** se envían las componentes cuya magnitud excede un umbral predefinido.

- **Random Sparsification:** se selecciona aleatoriamente un subconjunto de componentes, a menudo con probabilidad proporcional a su magnitud.




Fig. 5.9: Sparsification:

Más allá de los métodos clásicos basados en la representación euclídea de los gradientes, proponemos darle un enfoque desde el lado de la cuantización. Cada vector de actualización puede representarse como una medida empírica:

$$\mu_i = \frac{1}{d} \sum_{j=1}^d \delta_{v_{ij}},$$

donde v_{ij} son las componentes del vector $\Delta \mathbf{w}_i$. Al trabajar con μ_i pasamos al espacio métrico de medidas $\mathcal{W}_p(\mathbb{R}^d)$, donde la W_p es la métrica natural. Así, el objetivo es encontrar una medida discreta de soporte k que la aproxime bajo la distancia de Wasserstein W_p :

$$\tilde{\nu}_i = \arg \min_{\nu \in \mathcal{M}_k} W_p(\mu_i, \nu),$$

donde $\mathcal{M}_k$ es el conjunto de medidas con a lo sumo k átomos. Esta formulación equivale a una cuantización óptima de medidas. La medida cuantizada

$$\tilde{\nu}_i = \sum_{r=1}^k a_r \delta_{z_r}, \quad \text{con} \quad \sum_r a_r = 1,$$

puede transmitirse eficientemente mediante los k puntos z_r y sus pesos a_r , seguramente logrando una compresión significativa mientras se preserva la estructura geométrica de los gradientes.

Otra alternativa consiste en aplicar cuantización conjunta sobre los gradientes locales antes de enviarlos al servidor. En lugar de transmitir cada gradiente $\Delta w_i^{(b)}$ generado en cada minibatch durante una época, cada cliente puede acumular todos los gradientes locales de la época, interpretarlos como una colección de medidas, y luego construir una cuantización conjunta que capture su estructura estadística esencial mediante un conjunto reducido de puntos representativos. De este modo, el cliente envía únicamente la medida cuantizada, que resume de forma óptima la información contenida en todos los gradientes, en lugar de transmitir cada actualización individual. Esta estrategia no solo reduciría el costo de comunicación, sino que filtraría el posible ruido de cada minibatch, produciendo una actualización local más estable y representativa, preservando al mismo tiempo la geometría del espacio de gradientes.

Gran Volumen y Heterogeneidad de Datos a Nivel de Usuario

Un problema significativo en Federated Learning (FL) surge cuando un cliente individual (usuario) posee un volumen excesivamente grande de datos y estos datos provienen de múltiples fuentes o presentan distintas distribuciones dentro del mismo dispositivo.

El cliente puede ser un dispositivo con recursos restringidos que no dispone de la capacidad de cómputo ni del tiempo necesario para entrenar un modelo localmente utilizando todos sus datos.

Si los datos del usuario provienen de diversas fuentes (por ejemplo, un usuario que usa una aplicación en distintos contextos o que posee datos de múltiples orígenes), su conjunto de datos local no sigue una única distribución sino que consiste en una mezcla de distribuciones distintas. Además, un gran volumen de datos suele implicar alto costo computacional.

El objetivo es, por tanto, encontrar un subconjunto óptimo de datos que represente fielmente la distribución conjunta para el entrenamiento local. Por esto, proponemos realizar la cuantización conjunta previa al entrenamiento del modelo. La cuantización de medidas busca encontrar un conjunto discreto de puntos que capture de forma óptima la medida de probabilidad subyacente de los datos, resumiendo la información contenida en el conjunto de datos local en un número mucho menor de muestras representativas.

Otros objetivos de usar Federated Learning

En ciertos escenarios, el objetivo no es necesariamente aprender un modelo de predicción, sino más bien calcular una cantidad específica a partir de los datos almacenados en los clientes. Por ejemplo, un objetivo puede ser útil evaluar la similitud entre los conjuntos de datos de los distintos clientes. Esto permite analizar la heterogeneidad de los datos y aprovechar esta información para mejorar el rendimiento de los algoritmos de aprendizaje federado.

El objetivo central del trabajo en Federated Wasserstein Distance es calcular la distancia de Wasserstein (W_p) entre dos distribuciones de datos (μ y ν) en un servidor global. El desafío principal radica en que μ y ν están estrictamente separadas y distribuidas en dos clientes distintos, los cuales tienen prohibido compartir cualquier muestra de datos con el servidor.

Desde una perspectiva matemática, el problema se reformula a: estimar un elemento ξ^* que se encuentra en la geodésica que conecta μ y ν , sin acceso directo a ellas. Se aprovecha la siguiente propiedad del espacio: para cualquier elemento ξ^* en la geodésica entre μ y ν , se cumple la siguiente igualdad sobre la distancia:

$$W_p(\mu, \nu) = W_p(\mu, \xi^*) + W_p(\xi^*, \nu)$$

La estimación de ξ^* se logra aprovechando la información de otros dos elementos, ξ_μ y ξ_ν , que se encuentran, respectivamente, en las geodésicas de los pares (μ, ξ^*) y (ν, ξ^*) (ver fig. 5.10).

La aplicabilidad de esta propiedad geométrica conduce al desarrollo de **FedWaD** (**Federated Wasserstein Distance**), que calcula la distancia de Wasserstein de manera federada. Este algoritmo aproxima iterativamente el elemento ξ^* . El procedimiento opera de manera iterativa mediante dos pasos principales: Cálculo Local en los Clientes y Agregación Global y Actualización.

Los clientes computan sus distribuciones locales, ξ_μ^k y ξ_ν^k . Estas se derivan de las geodésicas entre la aproximación actual de ξ^* y las distribuciones de datos locales. ξ_μ^k y ξ_ν^k cumplen el rol de las versiones locales del modelo global ξ^* .

Luego, las distribuciones calculadas localmente (ξ_μ^k y ξ_ν^k) son enviadas al servidor, que las agrega para actualizar la aproximación ξ^* , guiándola hacia la posición real en la geodésica.

El funcionamiento iterativo del procedimiento **FedWaD** se ilustra en la Figura 5.10. Esta figura representa un espacio métrico donde μ (rojo) y ν (verde) son las distribuciones de datos privadas almacenadas en clientes distintos, y ξ_i representan

las aproximaciones del elemento geodésico ξ^* , el cual es el objetivo de estimación del servidor central.




Fig. 5.10: La distancia de Wasserstein entre μ y ν que están en sus respectivos clientes puede ser computada como $W_p(\mu, \nu) = W_p(\mu, \xi^*) + W_p(\nu, \xi^*)$ donde ξ^* es un elemento en la geodésica entre μ y ν . **FedWaD** busca estimar ξ^* con ξ^K usando un algoritmo iterativo y utiliza esta estimación para obtener $W_p(\mu, \nu)$. Los iterados ξ_i se computan en el servidor y se envían a los clientes para computar las medidas ξ_μ^i y ξ_ν^i que están en las geodésicas de μ y ξ_i y ν y ξ_i respectivamente.

La Complejidad del Transporte Óptimo

En el contexto de la Distancia de Wasserstein (W_p), el cálculo de los planes de transporte óptimo (OT) es la principal fuente de complejidad computacional. Inicialmente, para dos medidas discretas μ y ν con soportes de tamaño n y m respectivamente, la complejidad para computar un solo plan OT es del orden de $O((n + m)n \log(n + m))$.

El desafío en FedWaD es que, si bien el soporte de la estimación inicial $\xi^{(0)}$ puede ser pequeño (tamaño S), el soporte de las medidas interpoladoras ξ_μ y ξ_ν tiende a crecer con cada iteración k . Este aumento implica una sobrecarga computacional en el cómputo de las distancias parciales $W_p(\mu, \xi^k)$ y $W_p(\xi^k, \nu)$.

Para mitigar esta explosión de complejidad, en este trabajo proponemos emplear la cuantización conjunta como una estrategia alternativa y eficiente para aproximar

el cálculo del baricentro entre dos distribuciones de probabilidad fijando el tamaño de las aproximaciones en todas las iteraciones. Dadas dos distribuciones ξ y ξ' , seleccionamos de forma conjunta un conjunto de S puntos representativos que condensan la información más relevante de ambas medidas. Esta selección se realiza de modo que los puntos obtenidos sean óptimos con respecto al criterio de error considerado en el problema de cuantización, minimizando simultáneamente la distancia promedio de cada distribución a este conjunto reducido de puntos.

Una propiedad importante de este enfoque es que, al aumentar el número de puntos S , la aproximación converge al baricentro real de las distribuciones. Esto garantiza que el método reduce la complejidad del problema de manera coherente con la estructura geométrica subyacente de las medidas. Además, si el objetivo es cuantificar la distancia entre dos distribuciones sin necesidad de resolver el problema completo de transporte óptimo, la cuantización conjunta constituye una alternativa más simple. La distancia inducida por este procedimiento puede interpretarse como una medida de proximidad entre las distribuciones.

Desde el punto de vista computacional, el cálculo exacto del baricentro de Wasserstein entre dos o más distribuciones puede resultar costoso. En contraste, la cuantización conjunta ofrece una aproximación computacionalmente más liviana, al operar sobre un número acotado de puntos representativos.

En resumen, la cuantización conjunta permite obtener una representación reducida y compartida de dos distribuciones, que no solo facilita su comparación e interpolación, sino que además proporciona una herramienta útil para aproximar el baricentro de Wasserstein con bajo costo computacional, y para cuantificar de forma consistente la distancia entre ambas distribuciones.

6. CONCLUSIÓN

En esta tesis desarrollamos un marco teórico unificado para el estudio de la cuantización de medidas en espacios de Wasserstein, extendiendo la teoría clásica hacia escenarios más complejos donde intervienen múltiples distribuciones y, finalmente, medidas definidas sobre el propio espacio de medidas. A partir del análisis de la métrica de Wasserstein y del concepto de baricentro, se establecieron resultados de existencia, unicidad y convergencia de cuantizadores óptimos, así como la densidad de las medidas de soporte finito en $W_p(E)$. Estos resultados proporcionan una base sólida para justificar la aproximación de distribuciones arbitrarias mediante representaciones discretas con un número controlado de puntos.

Uno de los aportes principales del trabajo fue la introducción y el análisis de la *cuantización conjunta de medidas*. A diferencia de la cuantización tradicional, centrada en una única medida, aquí se estudió cómo construir una representación discreta común para varias distribuciones simultáneamente. Este enfoque permitió conectar de manera natural la cuantización con el problema del baricentro de Wasserstein. Si bien se mostró que el cuantizador del baricentro y el cuantizador conjunto no coinciden para un k fijo, también se probó que la sucesión de cuantizadores conjuntos converge hacia el baricentro cuando el número de puntos crece. Este resultado explica formalmente por qué la cuantización conjunta constituye un método válido para aproximar baricentros en contextos donde la discretización es necesaria o deseable.

En el último capítulo se mostraron aplicaciones concretas en aprendizaje automático, particularmente en *Conditional Flow Matching* para modelos generativos y en aprendizaje federado. Allí se discutió cómo las ideas de cuantización y cuantización conjunta permiten reducir la carga computacional y construir representaciones fieles a los datos. Estas aplicaciones muestran que los resultados teóricos no solo amplían la comprensión matemática del problema, sino que también poseen impacto práctico en el diseño de algoritmos modernos.

En conjunto, este trabajo demuestra que la cuantización de medidas en espacios de Wasserstein constituye una herramienta de interés en el ámbito teórico y el aplicado. La formulación de la cuantización conjunta y su conexión con los baricentros permite seguir estudiando tasas de convergencia, la integración con métodos numéricos de transporte óptimo y la exploración de aplicaciones en modelos generativos y

como método de compresión de datos. Los resultados presentados no solo amplían la teoría existente, sino que también sientan las bases para futuras líneas de estudio.

7. APÉNDICE

Definición 9 (Distancia). Una función sobre un conjunto X es una *distancia*,

$$D : X \times X \rightarrow [0, \infty)$$

tal que para cualesquiera que sean $x, y, z \in X$, se satisfacen las siguientes condiciones:

1. $D(x, y) = 0 \iff x = y$
2. $D(x, y) = D(y, x)$
3. $D(x, z) \leq D(x, y) + D(y, z)$

Definición 10 (Espacio Geodésico). Un espacio métrico (E, d) se llama espacio geodésico si para cada par de puntos $x, y \in E$, existe una curva $\gamma : [0, T] \rightarrow X$ tal que $\gamma(0) = x$, $\gamma(T) = y$, y la longitud de la curva $L(\gamma)$ es igual a la distancia métrica entre x e y , es decir:

$$L(\gamma) = d(x, y)$$

Además, la curva γ está parametrizada proporcionalmente a la longitud, lo que significa que para todo $0 \leq t_1 \leq t_2 \leq T$, se cumple:

$$d(\gamma(t_1), \gamma(t_2)) = \frac{t_2 - t_1}{T} d(x, y)$$

Tal curva γ se denomina **geodésica** entre x e y .

Definición 11 (Conjunto precompacto). Sea (E, d) un espacio métrico. Un subconjunto $A \subset E$ se dice *precompacto* si toda sucesión $(x_n)_{n \geq 1}$ en A tiene una subsucesión que converge en E .

Definición 12 (Familia tight). Sea X un espacio y $\{\mu_j\}_{j \in J}$ una familia de medidas de probabilidad sobre X . Decimos que la familia es *tight* si

$$\forall \varepsilon > 0, \exists K_\varepsilon \subset X \text{ compacto tal que } \mu_j(K_\varepsilon) \geq 1 - \varepsilon, \quad \forall j \in J.$$

Definición 13 (Semicontinuidad inferior). Sea (X, d) un espacio métrico y $F : X \rightarrow \mathbb{R} \cup \{+\infty\}$ una función. Decimos que F es *semitcontinua inferiormente* en $x \in X$ si, para toda sucesión (x_n) con $x_n \rightarrow x$, se cumple

$$\liminf_{n \rightarrow \infty} F(x_n) \geq F(x).$$

Proposición 2 (Semicontinuidad inferior de W_p). Sea (μ_n) una sucesión en $\mathcal{P}_p(X)$ tal que $\mu_n \rightarrow \mu$ débilmente. Entonces, para toda $\nu \in \mathcal{P}_p(X)$ se cumple

$$\liminf_{n \rightarrow \infty} W_p(\mu_n, \nu) \geq W_p(\mu, \nu).$$

Lema 3. Sea $(\mu_n)_{n \geq 1}$ una sucesión de medidas en un espacio polaco (E, d) que converge débilmente hacia μ . Si existe una medida ν tal que

$$W_p(\mu_n, \nu) \rightarrow W_p(\mu, \nu),$$

entonces

$$W_p(\mu_n, \mu) \rightarrow 0.$$

Demostración. La demostración de este lema se encuentra en [5] □

Teorema 8 (Teorema de Skorohod). Sea (E, d) un espacio métrico y $(\mu_n)_{n \geq 1}$ una sucesión de medidas de probabilidad en $\mathcal{M}$. Si $\mu_n \Rightarrow \mu$ (es decir, μ_n converge débilmente a μ), entonces existe un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$ y variables aleatorias

$$X_n, X : \Omega \rightarrow M$$

tales que

$$X_n \sim \mu_n, \quad X \sim \mu, \quad \text{y} \quad X_n \rightarrow X \text{ c.s.}$$

Lema 4 (Lema de Fatou). Sea $(f_n)_{n \geq 1}$ una sucesión de funciones medibles no negativas, $f_n : M \rightarrow [0, +\infty]$. Entonces:

$$\int_M \liminf_{n \rightarrow \infty} f_n(x) d\mu(x) \leq \liminf_{n \rightarrow \infty} \int_M f_n(x) d\mu(x).$$

Teorema 9 (Teorema de Convergencia Dominada). Sea $(X_n)_{n \geq 1}$ una sucesión de variables aleatorias tal que

$$X_n \xrightarrow[n \rightarrow \infty]{c.s.} X.$$

Si existe una variable aleatoria integrable Y con

$$|X_n| \leq Y \quad \text{c.s., } \forall n,$$

entonces

$$\lim_{n \rightarrow \infty} \mathbb{E}[X_n] = \mathbb{E}[X].$$

Proposición 3 (Desigualdad de Minkowski). Sean $(X, \mathcal{F}, \mu)$ un espacio de medida, $f, g \in \mathcal{M}(X, \mathcal{F}, \mathbb{C})$ y $p \in [1, +\infty)$. Entonces

$$N_p(f + g) \leq N_p(f) + N_p(g),$$

esto es,

$$\left(\int_X |f + g|^p d\mu \right)^{1/p} \leq \left(\int_X |f|^p d\mu \right)^{1/p} + \left(\int_X |g|^p d\mu \right)^{1/p}.$$

Lema 5 (Gluing Lema). Sea (E_i, μ_i) , $i = 1, 2, 3$, un espacio de probabilidad polaco. Si (X_1, X_2) es un acoplamiento de (μ_1, μ_2) y (Y_2, Y_3) es un acoplamiento de (μ_2, μ_3) , entonces se puede construir una terna de variables aleatorias (Z_1, Z_2, Z_3) tal que (Z_1, Z_2) tiene la misma ley que (X_1, X_2) y (Z_2, Z_3) tiene la misma ley que (Y_2, Y_3) .

Proposición 4. Resultado extraído de [6]. Sea μ una medida de probabilidad simétrica respecto del origen con $\mu(\{0\}) = 0$ y $|\text{supp}(\mu)| \geq m$. Definimos la restricción de μ al semieje positivo o la versión “one-tailed” de μ como:

$$\tilde{\mu} := \mu|_{[0, \infty)}.$$

Si $\alpha \subset (0, \infty)$, $k \in \mathbb{N}$ y α un cuantizador de μ , entonces $\alpha \subset (0, \infty)$ (no puede haber $a \leq 0$ como centro óptimo, pues tendría masa cero). Además, para $\alpha \subset (0, \infty)$ se cumple

$$\alpha \cup (-\alpha) \in S_{2k,r}(\mu) \iff \alpha \in S_{k,r}(\tilde{\mu}).$$

Al reflejar α por el origen obtenemos una configuración simétrica de los centros. Luego, si n es par ($n = 2k$) siempre existe un conjunto simétrico para μ . Basta tomar cualquier α en el conjunto de cuantizadores para $\tilde{\mu}$ y reflejar. Si n es impar, esto puede fallar.

Ejemplo 5. Sea μ una distribución uniforme en $[-2, -1] \cup [1, 2]$ y sea $n = 3$. Buscamos minimizar el error cuadrático medio. Los cuantizadores óptimos son

$$\left\{ -\frac{7}{4}, -\frac{5}{4}, \frac{3}{2} \right\} \quad \text{o} \quad \left\{ -\frac{3}{2}, \frac{5}{4}, \frac{7}{4} \right\}.$$

Sin embargo,

$$\left\{-\frac{3}{2}, 0, \frac{3}{2}\right\}$$

no es cuantizador óptimo, pues los puntos x para los cuales está más cerca de 0 que de otros centros son aquellos en

$$x \in \left[-\frac{3}{4}, \frac{3}{4}\right],$$

y como $\mu([-3/4, 3/4]) = 0$, no puede ser válida.

Si $\alpha \cup (-\alpha)$ es un centro óptimo de n puntos (con $n = 2k$), entonces α es un centro óptimo para $\tilde{\mu}$ y $\alpha \subset (0, \infty)$. En general, el costo de cuantizar a μ con μ_{2k}^* (cuantizador óptimo soportado en a lo sumo $2k$ puntos) es menor o igual al costo de cuantizar a $\tilde{\mu}$ con $\tilde{\mu}_k^*$ (cuantizador óptimo soportado en a lo sumo k puntos). La igualdad se da si existe un cuantizador óptimo para μ que sea simétrico.

Lema 6 (Continuidad de la función de error). Sea (E, d) un espacio métrico polaco y $p \geq 1$.

(a) Si $\mu_1, \dots, \mu_N \in \mathcal{W}_p(E)$ y

$$\ell(\nu) := \sum_{i=1}^N \lambda_i W_p(\nu, \mu_i), \quad \nu \in \mathcal{W}_p(E),$$

con $\lambda_i > 0$, $\sum_i \lambda_i = 1$, entonces ℓ es continua en $(\mathcal{W}_p(E), W_p)$.

(b) Más generalmente, si $\mathbb{P} \in \mathcal{W}_p(\mathcal{W}_p(E))$ y definimos

$$\ell(\nu) := \left(\int_{\mathcal{W}_p(E)} W_p^p(\nu, \tilde{\mu}) dP(\tilde{\mu}) \right)^{1/p}, \quad \nu \in \mathcal{W}_p(E),$$

entonces ℓ es continua en $(\mathcal{W}_p(E), W_p)$.

Demostración. (a) Cada aplicación $\nu \mapsto W_p(\nu, \mu_i)$ es continua en $(\mathcal{W}_p(E), W_p)$. Como ℓ es suma finita de funciones continuas, resulta continua.

(b) Sea (ν_n) una sucesión en $\mathcal{W}_p(E)$ con $\nu_n \rightarrow \nu$ en W_p . Entonces, para cada $\tilde{\mu} \in \mathcal{W}_p(E)$ se cumple

$$W_p^p(\nu_n, \tilde{\mu}) \longrightarrow W_p^p(\nu, \tilde{\mu}).$$

Además, por la desigualdad triangular,

$$W_p(\nu_n, \tilde{\mu}) \leq W_p(\nu_n, \nu) + W_p(\nu, \tilde{\mu}),$$

Elevando a la p -ésima potencia y aplicando la desigualdad elemental $(a + b)^p \leq 2^{p-1}(a^p + b^p)$ para $p \geq 1$, obtenemos

$$W_p^p(\nu_n, \tilde{\mu}) \leq 2^{p-1}W_p^p(\nu_n, \nu) + 2^{p-1}W_p^p(\nu, \tilde{\mu}).$$

Note que $W_p^p(\nu_n, \nu)$ no depende de $\tilde{\mu}$. Como $\nu_n \rightarrow \nu$, la sucesión $W_p^p(\nu_n, \nu)$ converge a 0 y en particular está acotada: existe $M < \infty$ tal que

$$W_p^p(\nu_n, \nu) \leq M \quad \text{para todo } n.$$

Así, para todo n y toda $\tilde{\mu}$ se cumple

$$W_p^p(\nu_n, \tilde{\mu}) \leq 2^{p-1}M + 2^{p-1}W_p^p(\nu, \tilde{\mu}).$$

Por tanto podemos tomar como dominante

$$g(\tilde{\mu}) := 2^{p-1}M + 2^{p-1}W_p^p(\nu, \tilde{\mu}).$$

Necesitamos verificar que

$$\int g(\tilde{\mu}) dP(\tilde{\mu}) < \infty.$$

Basta ver que $\int W_p^p(\nu, \tilde{\mu}) dP(\tilde{\mu}) < \infty$. Como $P \in \mathcal{W}_p(\mathcal{W}_p(E))$, por definición existe una medida de referencia $\mu_0 \in \mathcal{W}_p(E)$ tal que

$$\int W_p^p(\mu_0, \tilde{\mu}) dP(\tilde{\mu}) < \infty.$$

Aplicamos de nuevo la desigualdad triangular y la cota $(a + b)^p \leq 2^{p-1}(a^p + b^p)$:

$$W_p(\nu, \tilde{\mu}) \leq W_p(\nu, \mu_0) + W_p(\mu_0, \tilde{\mu}),$$

$$W_p^p(\nu, \tilde{\mu}) \leq 2^{p-1}W_p^p(\nu, \mu_0) + 2^{p-1}W_p^p(\mu_0, \tilde{\mu}).$$

Integrando respecto de P ,

$$\int W_p^p(\nu, \tilde{\mu}) dP(\tilde{\mu}) \leq 2^{p-1} W_p^p(\nu, \mu_0) + 2^{p-1} \int W_p^p(\mu_0, \tilde{\mu}) dP(\tilde{\mu}) < \infty.$$

Así g es efectivamente integrable respecto a P .

Entonces por el Teorema de Convergencia Dominada obtenemos

$$\int W_p^p(\nu_n, \tilde{\mu}) dP(\tilde{\mu}) \longrightarrow \int W_p^p(\nu, \tilde{\mu}) dP(\tilde{\mu}).$$

Por continuidad de la raíz p -ésima, concluimos que $\ell(\nu_n) \rightarrow \ell(\nu)$. □

Bibliografía

- [1] Cédric Villani. *Optimal Transport: Old and New*, volume 338 of *Grundlehren der mathematischen Wissenschaften*. Springer, 2009.
- [2] Victor M. Panaretos and Yoav Zemel. *An Invitation to Statistics in Wasserstein Space*. Springer Briefs in Probability and Mathematical Statistics. Springer, Cham, 2020.
- [3] Nicolás Gustavo Chehebar. Transporte óptimo y baricentro con distancia de fermat. Tesis de licenciatura, Universidad de Buenos Aires, Facultad de Ciencias Exactas y Naturales, Buenos Aires, 2021. Director: Dr. Pablo Groisman.
- [4] Martial Agueh and Guillaume Carlier. Barycenters in the wasserstein space. *SIAM Journal on Mathematical Analysis*, 43(2):904–924, 2011.
- [5] Thibaut Le Gouic and Jean-Michel Loubes. Existence and consistency of wasserstein barycenters. *Probability Theory and Related Fields*, 168(3-4):901–917, 2017.
- [6] Siegfried Graf and Harald Luschgy. *Foundations of Quantization for Probability Distributions*, volume 1730 of *Lecture Notes in Mathematics*. Springer, 2000.
- [7] Nicolas Chéhère. Quantization and empirical measures: A probabilistic approach. *ESAIM: Probability and Statistics*, 24:580–602, 2020.
- [8] David Pollard. Quantization and the method of k -means. *IEEE Transactions on Information Theory*, 1982.
- [9] Alexander Tong, Nikolay Malkin, Guillaume Huguet, Yanlei Zhang, Jarrid Rector-Brooks, Kilian Fatras, Guy Wolf, and Yoshua Bengio. Conditional flow matching: Simulation-free dynamic optimal transport. *CoRR*, abs/2302.00482, 2023.
- [10] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. In *Proceedings of the International Conference on Learning Representations*, 2023.

-
- [11] Peter Kairouz, H. Brendan McMahan, Brendan Avent, Aurélien Bellet, Mehdi Bennis, Arjun Nitin Bhagoji, Kallista Bonawitz, Zachary Charles, Graham Cormode, Rachel Cummings, Rafael G. L. D'Oliveira, Hubert Eichner, Salim El Rouayheb, David Evans, Josh Gardner, Zachary Garrett, Adrià Gascón, Badi Ghazi, Phillip B. Gibbons, Marco Gruteser, Zaid Harchaoui, Chaoyang He, Zhouyuan Huo, Ben Hutchinson, Justin Hsu, Martin Jaggi, Tara Javidi, Gauri Joshi, Mikhail Khodak, Jakub Konečný, Aleksandra Korolova, Farinaz Koushanfar, Sanmi Koyejo, Tancrède Lepoint, Yang Liu, Prateek Mittal, Mehryar Mohri, Richard Nock, Ayfer Özgür, Rasmus Pagh, Hang Qi, Daniel Ramage, Ramesh Raskar, Mariana Raykova, Dawn Song, Weikang Song, Sebastian U. Stich, Ziteng Sun, Ananda Theertha Suresh, Florian Tramer, Praneeth Vepakomma, Jianyu Wang, Li Xiong, Zheng Xu, Qiang Yang, Sen Zhao, Han Yu Zhu, et al. Advances and open problems in federated learning. *arXiv preprint arXiv:1912.04977*, 2021.
- [12] Peter Kairouz, Zheng Xu, Katharine Daly, Hubert Eichner, H. Brendan McMahan, and Daniel Ramage. Federated learning in practice: Reflections and projections. *arXiv preprint arXiv:2410.08892*, 2024.
- [13] Yujun Lin, Song Han, Huizi Mao, Yu Wang, and William J. Dally. Deep gradient compression: Reducing the communication bandwidth for distributed training. *arXiv preprint arXiv:1712.01887*, 2018.
- [14] Subrato Bharati, M. Rubaiyat Hossain Mondal, Prajoy Podder, and V. B. Surya Prasath. Federated learning: Applications, challenges and future directions. *Engineering Applications of Artificial Intelligence*, 121:106056, 2023.
- [15] Siegfried Graf and Harald Luschgy. Rates of convergence for quantization of probability distributions. *Annals of Probability*, 27(2):904–947, 1999.
- [16] Peter M. Gruber. Optimum quantization and its applications. *Advances in Mathematics*, 186(2):456–497, 2004.
- [17] H. Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Agüera y Arcas. Communication-efficient learning of deep networks from decentralized data. *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 54:1273–1282, 2017. arXiv preprint arXiv:1602.05629.